Universidad Autónoma del Estado de Hidalgo

Instituto de Ciencias Básicas e Ingenierías

Licenciatura en Matemáticas Aplicadas

Reto AgroCebada 2026

Presentada por:

Alan Yael Diaz Vizzuett

Brayan Uriel Islas Sánchez

Brenda Esmeralda Martínez de la Cruz

Chac de Jesús Moreno Torres

Jared Sánchez Martínez

Mineral de la Reforma, Hidalgo
18 de octubre de 2026

Introducción

En la actualidad la agricultura tiene cada vez más problemas: los suelos se desgastan, el clima cambia y las lluvias ya no llegan igual cada año, así que un cultivo puede dar buenos resultados un año y al siguiente malos. Por eso es importante poder saber, de las cosechas, cómo le va a ir al cultivo.

En Hidalgo, Tlaxcala y Puebla la cebada es uno de los cultivos más importantes, y Hidalgo es de los estados que más la siembra en el país (SIAP, 2023). La mayoría se siembra de temporal, es decir, depende de la lluvia, por lo que un año seco puede afectar mucho la producción.

Considerando esto, es menéster prestar atención a la fluctuación de las precipitaciones en los últimos años, dado que la cebada es una hortaliza muy sensible al cambio climático, lo que supone un reto muy importante para los productores,aún más para aquellos que se dedican a la producción por cultivo temporal, ya que un fenómeno natural inesperado como una sequía o demasiadas precipitaciones llegan a estresar la planta mermando su rendimiento de manera considerable.

El cultivo por temporal es una práctica que con el paso del tiempo ha ido a la baja debido al cambio climático y los problemas que han derivado de este, es común que muchos productores terminen migrando a otrás técnicas de riego artificiales como el riego con aguas residuales, esto con el fin de no depender tanto de la estabilidad climática a lo largo del año. De esta forma los productores por lo menos se aseguran de mantener el riego necesario para el crecimiento de sus cutivos.

Evidentemente esto representa una desventaja para los productores que se mantienen bajo la técnica de riego temporal, consideremos que algunos de ellos no migran a sistemas de riego artificiales no porque no quieran, si no por que quizá no cuentan con el presupuesto necesario para montar el equipo necesario o en sus localidades no existe la infraestructura necesaria para el riego con aguas residuales, como presas, canales y plantas tratadoras. Además de que si las aguas con las que se riega el cultivo no son tratadas de manera adecuada a la larga pueden representar un riesgo a la salud en comparación con el riego por temporal.

Una forma de seguir cómo van los cultivos es con imágenes satelitales. A partir de ellas se calculan índices que nos dicen qué tan verde está una parcela, cuánta agua tiene o si ya se está secando. Si juntamos esa información a lo largo del tiempo, podemos ver cómo se desarrolla el cultivo durante todo el ciclo.

En este trabajo, como parte del Reto AgroCebada 2026 de FIRA, analizamos series de tiempo de índices satelitales, lluvia y temperatura de 197 parcelas de cebada. Con esto buscamos entender cómo se comporta el cultivo a través del tiempo y construir un modelo que prediga su rendimiento.

El documento presentado consta de seis secciones mediante las cuales se pretende plasmar un panorama del propósito del proyecto, los desafíos y métodos que se emplearon para superarlos y los resultados obtenidos así como las áreas de oportunidad.

En la primera y segunda sección se presentan las bases sobre las que se comenzó, presentando el objetivo general y los objetivos específicos mediante los cuales se prentende alcanzar el resultado esperado. También se presenta la defición de las herramientas y variables a considerar para la construcción del modelo, con la intención de que el lector cuente con las definiciones básicas sobre las que se trabajó.

Con las secciones tres y cuatro buscamos brindar una introducción a los métodos empleados para el análisis de las bases de datos proporcionadas por el Reto Agrocebada y las rescatadas de las imágenes satelitales. Partiendo de las Series de tiempo que nos permiten observar si las condiciones clímaticas siguen un patrón para identificar la dependencia de precipitaciones entre períodos. Después se presenta una introducción detallada al modelo de regresión líneal que fue el elegido para realizar nuestras estimaciones.

En la quinta sección presentamos la metodología que seguimos usando las técnicas expuestas en las secciones anteriores. Describimos los factores que consideramos para la limpieza de los datos, las conclusiones obtenidas del análisis de las series de tiempo que a la postre nos ayudaron a plantear los modelos necesarios para realizar las predicciones del rendmiento por cultivos.

Finalmente se presentan los resultados obtenidos. Se proporciona la versión final del modelo predictivo y se muestra la precisición del mismo así como los parámetros que la sustentan. Así mismo se incluye una comparación entre el promedio de las estimaciones del modelo y el promedio real observado así como una revisión de la literatura para comprobar la precisión de nuestro modelo con otras investigaciones similares disponibles de manera pública.

Justificación

El poder predecir el rendimiento de un cultivo, ya hablando en general de cualquier cultivo, es poder detectar a tiempo si el cultivo va a rendir o no, ya que la planta, en cualquier etapa fenológica, pudo sufrir un fuerte estrés y no rendir lo que debía, y así poder aplicar técnicas agronómicas para hacer lo necesario para corregirlo. Esto es importante porque, si el cultivo no rinde lo necesario, en lugar de producir ganancias el productor podría perder dinero.

Para lograrlo, primero necesitamos entender el cultivo: por ejemplo, en qué época conviene sembrarlo, cómo le afecta el clima (que va variando cada vez más) y cómo cambian condiciones como la temperatura de las parcelas a lo largo del ciclo. Por eso, en este trabajo usamos series de tiempo, que nos permiten ver cómo se comportan estas variables durante todo el ciclo del cultivo.

Objetivos

Objetivo general

Predecir el rendimiento del cultivo de cebada en parcelas de Hidalgo, Tlaxcala y Puebla con índices satelitales, clima y topografía, usando análisis de series de tiempo y un modelo predictivo, para apoyar la toma de decisiones de los productores agrícolas de dicho cultivo.

Objetivos específicos

- Analizar los datos proporcionados por el reto para conocer su estructura y las variables disponibles.
- Extraer la información de las imágenes .tif utilizando RStudio.
- Depurar los datos satelitales eliminando imágenes con un alto porcentaje de nubosidad.
- Seleccionar las variables más importantes para el rendimiento con base en su significado agronómico.
- Verificar la regularidad de las series de tiempo y, en caso de que no lo sean, hacerlas regulares.
- Analizar las series de tiempo para identificar su tendencia, estacionalidad, varianza, cambios estructurales, valores atípicos, estacionariedad y autocorrelación usando RStudio.
- Usar RStudio para identificar qué modelo se usará en las series de tiempo.
- Construir y ajustar un modelo de regresión lineal múltiple para estimar el rendimiento de la cebada a partir de las variables seleccionadas.
- Validar la precisión y confiabilidad del modelo predictivo mediante el análisis de residuales y métricas de error (como RMSE y MAE).
- Desarrollar e implementar una aplicación web interactiva utilizando `shiny` para visualizar los resultados, realizar predicciones en tiempo real y simular distintos escenarios climáticos.

Marco teórico

Cebada

La cebada es un cereal que se destina para la alimentación humana, forraje y a la producción de malta (cerveza). En México se cultiva principalmente para producir grano de calidad para malta, materia prima para la industria cervecera, por lo que tanto la cantidad como la calidad del grano tienen una gran importancia económica para sus productores, ya que varias familias dependen de ello. En los tres estados que se nos otorgan los datos, es decir, Hidalgo, Tlaxcala y Puebla, son unos de los estados con la mayor producción de este cultivo, ya que en el 2022 estos tres estados se encontraron en los primeros lugares en superficie sembrada de cebada, donde Hidalgo ocupó el primer lugar, mientras que Tlaxcala y Puebla el tercero y quinto (SIAP, 2023).

Otro dato que es importante mencionar es que la mayor parte de la producción de cebada se obtiene en condiciones de temporal, durante el ciclo primavera-verano (Zamora Díaz et al., 2010). En la región de estos tres estados, la siembra se realiza en el verano, por lo que el cultivo depende casi por completo de la lluvia. Esto es lo que hace que sea sensible a la cantidad de agua y al momento en que llueve. También es una de las mejores alternativas para las zonas de los Valles Altos de México, ya que su ciclo es algo corto, lo que permite producir en condiciones en que otros cultivos no se darían.

Las zonas productoras se ubican a gran altitud y con temperaturas templadas; por ejemplo, en Hidalgo se cultiva en localidades como Apan y Almoloya, que se encuentran a más de 2,500 metros sobre el nivel del mar y con temperaturas promedio de entre 12 y 14 grados centígrados (Gómez Mercado et al., 2009).

escogimos la escala Zadoks, ya que toma en cuenta su germinación y es una de las más usadas. Para ello vamos a adjuntar la siguiente tabla para poder entender un poco mejor este cultivo.

Cuadro 1: Fases de desarrollo de la cebada según la escala de Zadoks.

Etapa	Descripción	Sub-fase	Etapa	Descripción	Sub-fase
0	La semilla germina	0.0–0.9	5	Sale la espiga	5.0–5.9
1	Salen las primeras hojas	1.0–1.9	6	Floración	6.0–6.9
2	La planta forma nuevos tallos (macollos)	2.0–2.9	7	El grano se llena (grano lechoso)	7.0–7.9
3	El tallo crece y se alarga	3.0–3.9	8	El grano se endurece (grano pastoso)	8.0–8.9
4	La espiga se forma dentro de la hoja (embuche)	4.0–4.9	9	El grano madura y la planta se seca	9.0–9.9

Fuente: elaboración propia con base en la escala de Zadoks.

Ya una vez sabiendo cómo se va comportando la cebada en sus etapas fenológicas gracias a la escala Zadoks, notemos que el llenado del grano (Z4–Z8) es cuando se define cuántos granos tendrá la planta y qué tan bien se llenarán, así que la falta de agua, mucho calor o una helada en ese periodo reducirían el rendimiento de la cosecha. Cabe aclarar que en esta escala no vienen fechas de qué mes a qué mes es cada etapa ni nada de eso; para ello nos guiaremos de un índice importante, que es el EVI de 2025, ya que es el año de siembra y cosecha de este cultivo.

Índices satelitales

Para este trabajo utilizamos la información proporcionada por el Reto AgroCebada 2026 de FIRA, que corresponde a 197 parcelas de cebada ubicadas en los estados de Hidalgo, Tlaxcala y Puebla. De estas 197 parcelas, 138 cuentan con el rendimiento obtenido en el ciclo abril-octubre de 2025, y las 59 restantes son parcelas donde se tendrá que predecir.

Nos proporcionaron dos conjuntos de datos. Uno es el conjunto de datos básico, donde vienen índices satelitales de dos sensores diferentes (Sentinel-2 y Landsat), los cuales tienen una cobertura del 2022 al 2025; son datos que estos dos satélites recolectaron a lo largo de estos 4 años de las 197 parcelas. Luego, también los organizadores del reto nos proporcionaron otros archivos .tif de donde extrajimos otras bases de datos, las cuales son la precipitación en milímetros de las parcelas, la temperatura mínima y máxima, la elevación y la pendiente. La temperatura mínima y máxima fueron dadas por CHIRTS-ERA5 y la precipitación por CHIRPS; la elevación fue proporcionada por el INEGI (CEM 4.0) y la pendiente se calculó a partir del CEM. Recordando que estos datos son de los tres estados ya mencionados.

Algo importante que es de mencionar es el hecho de que en el cultivo de estas 197 parcelas la forma de riego fue de temporal en su totalidad, es decir, que el cultivo solo dependió 100 por ciento de la lluvia. Así que, si hubo meses en que no llovió, la planta pudo haber sufrido algún estrés por falta de agua. Es importante mencionar que, si al momento en que la cebada está en la etapa fenológica de generar el grano tuvo algún estrés por falta de agua, bien pudo pasar que el grano no haya crecido bien, que no se llenara bien o problemas similares; así que la lluvia juega un papel de suma importancia en estas parcelas.

Como ya dijimos, venían dos sensores: Sentinel-2 nos proporcionó 22 índices, mientras que el otro sensor, Landsat, solo nos proporcionó el índice VI6T. Cabe aclarar que, para hacer el análisis de series de tiempo, en sí es muy tardado trabajar con muchas variables; por ello se optó por reducir variables y decidir cuáles son las más importantes desde nuestro punto de vista y cuáles podrían ayudarnos a predecir mejor el rendimiento. Se optó por variables que nosotros entendiéramos qué hacen y por su significado agronómico:

- EVI: índice de vigor vegetal diseñado para reducir parte de la influencia del suelo y de efectos atmosféricos. Es como el NDVI, pero, como dice arriba, mitiga los errores que pudo tener el NDVI.
- MSI: índice sensible al contenido de agua de la vegetación y al estrés hídrico. Es de importancia, ya que el cultivo es de temporal.
- NDSVI: índice sensible a vegetación senescente y material vegetal no fotosintético. Indica cuándo pasa el cultivo de verde a secarse, para después su cosecha.

Estas variables fueron tomadas del sensor Sentinel-2.

En la otra base de datos, en la base PRO, nos proporcionan 4 índices vegetativos; unos son iguales a los de la base BÁSICA, pero en esta solo vienen datos del 2025, es decir, de la fecha en que se sembró y se cosechó la cebada. Por eso mismo nosotros escogimos el EVI de Planet, ya que mide lo mismo que el de Sentinel-2, pero este viene con más tomas, ya que casi son diarias, y tiene más resolución.

Cabe aclarar que a cada base que se nos proporcionó se le hizo un filtro conforme al porcentaje de nubosidad, ya que, si hubo 100 por ciento de nubes el día que se tomó el dato, ese día viene todo vacío. Investigando, encontramos que una mejor filtración, sin perder mucha información y datos, es tener solo un 20 por ciento de nubes o menos. Investigando, encontramos que una mejor filtración, sin perder mucha información y datos, es tener solo un 20 por ciento de nubes o menos [4, 5].

Temperatura

Dado el archivo .zip otorgado por el Reto AgroCebada 2026 de FIRA, se recopiló información importante de unas imágenes .tif, de tal modo que estas imágenes contenían información sobre la temperatura mínima y máxima de cada parcela, la cual viene por año y mes. Esta variable en la cultura agronómica es de importancia, ya que a algunas plagas les gusta estar en ciertas condiciones de clima para poder propagarse mejor; también depende de ella el crecimiento del cultivo, ya que, si hubo una helada fuerte, el cultivo pudo sufrir algún tipo de estrés y por tanto no crecer como debía o no dar el rendimiento que uno quería. Lo mismo podemos decir de la temperatura máxima, ya que, en una de esas donde no llovió pero hubo un calor muy fuerte, el cultivo pudo sufrir quemaduras o algún estrés por agua, y ahí es donde entra la variable MSI que escogimos en la base BÁSICA. Todo se tomó con base en una lógica: intentamos pensar como agricultores.

Precipitación

Esta variable sí o sí la debemos emplear, ya que se cultivaron bajo condiciones de temporal (FIRA, comunicación personal). Si no llovió lo suficiente ese año, el rendimiento no será el mismo; o, si no llueve, la planta sufre estrés, dependiendo de en qué etapa estaba, ya que, si está en la etapa de llenado (Z4–Z8), no va a rendir lo que debía. Por eso es importante saber cómo se comporta esta variable. Esta base de datos viene del año 2022 al 2025, lo cual es importante, ya que se hizo un análisis de series de tiempo y llegamos a que la lluvia de cualquier mes no depende de la lluvia del mes pasado, pero la lluvia de este año sí está relacionada con la lluvia de hace un año, y más aún, la lluvia de este mes está relacionada con la lluvia del mismo mes pero de hace un año, lo cual dijimos que tiene todo el sentido del mundo, ya que por algo es un cultivo de temporal; si no fuera así, uno estaría con la duda de cuándo sembrar debido a las condiciones variantes. También se escogieron variables de la precipitación conforme a su etapa de la cebada, ya que algo que se debe tener claro es que, si la cebada tiene una deficiencia de agua al momento de germinar o al formar el grano, no se tendrá el rendimiento esperado. Para ello usamos la lluvia acumulada en la temporada de siembra y cosecha, es decir, de abril a octubre: vimos cuánto llovió en cada parcela en total.

Topografía

Esta variable es fija, es decir, no cambia a través del tiempo. En los archivos .tif que nos proporcionó el reto venían datos importantes de las parcelas, los cuales fueron su elevación sobre el nivel del mar y la pendiente de la parcela. Estos datos vienen del INEGI, del Continuo de Elevaciones Mexicano (CEM 4.0), y la pendiente se calculó a partir de la elevación.

Aunque es un dato fijo, la consideramos importante al hacer el modelo. La elevación nos dice qué tan alta está la parcela, y entre más alta, más frío hace y hay más riesgo de heladas, lo que puede afectar al cultivo. La pendiente nos dice qué tan inclinado está el terreno; si está muy inclinado, el agua de la lluvia se escurre más rápido y la planta aprovecha menos agua, y como el cultivo es de temporal, eso es importante.

Series de tiempo

Vamos a hablar un poco del análisis que hicimos para poder hacer el modelo. Uno de ellos fue el análisis de series de tiempo; en sí, no lo usamos para predecir el rendimiento, sino para entender mejor el comportamiento de las variables a través del tiempo, ya que nos dieron datos del 2022 al 2025. Por eso vamos a empezar por decir qué es una serie de tiempo y cómo podemos hacer un análisis en RStudio.

¿Qué es una serie de tiempo?

Una serie de tiempo es una colección de observaciones ordenadas temporalmente:

$$\{Y_t\}$$

donde t representa el tiempo. Ejemplos:

- PIB trimestral
- Inflación mensual
- Temperatura diaria
- Precio de una acción
- Desempleo trimestral

La característica fundamental es que Y_t puede depender de $Y_{t-1}, Y_{t-2}, \ldots$ Por lo tanto, las observaciones no necesariamente son independientes.

Series regulares

Una serie es regular cuando las observaciones se encuentran igualmente espaciadas en el tiempo. Por ejemplo:

- Cada mes: enero, febrero, marzo, ...
- Cada trimestre
- Cada año
- Cada día

En R, una serie mensual puede representarse mediante:

```
ts(datos, start = c(2010, 1), frequency = 12)
```

donde `frequency = 12` indica 12 observaciones por año.

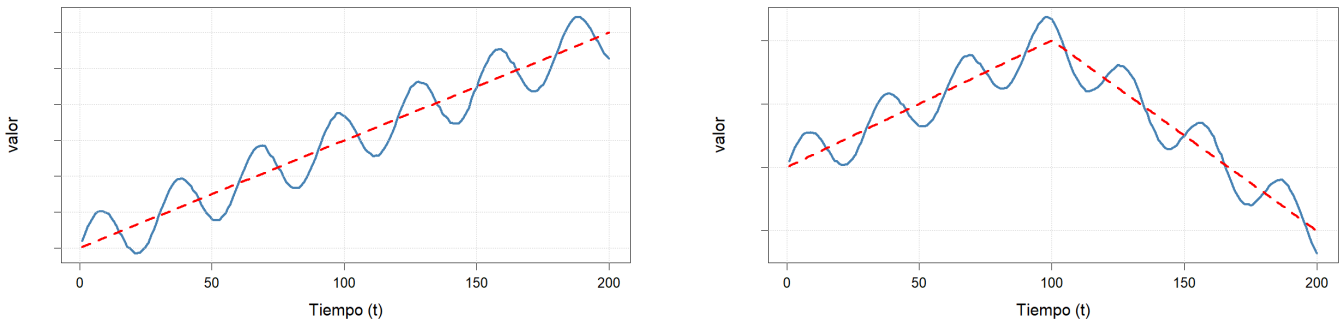
Primer paso: visualizar la serie

Antes de estimar cualquier modelo debemos observar la serie. Debemos preguntarnos unas cosas importantes:

- ¿Existe una tendencia?
- ¿Existe estacionalidad?
- ¿La varianza parece constante?
- ¿Hay cambios estructurales?
- ¿Existen valores atípicos?
- ¿Existe autocorrelación?

En R:

```
plot(y, main = "Serie de tiempo", ylab = "y", xlab = "Tiempo")
```



(a) Sin cambio estructural

(b) Con cambio estructural

Figura 1: Comparación de series de tiempo con y sin cambio estructural.

La inspección gráfica es importante, pero no es suficiente para determinar la estacionariedad.

¿Qué significa que una serie sea estacionaria?

Una serie es débilmente estacionaria si sus principales propiedades estadísticas no dependen del tiempo. Para una serie Y_t:

$$E(Y_t) = \mu$$

$$\text{Var}(Y_t) = \sigma^2$$

y la covarianza depende solamente del rezago k:

$$\text{Cov}(Y_t, Y_{t-k}) = \nu_k$$

En particular:

$$\text{Corr}(Y_t, Y_{t-k}) = \rho_k$$

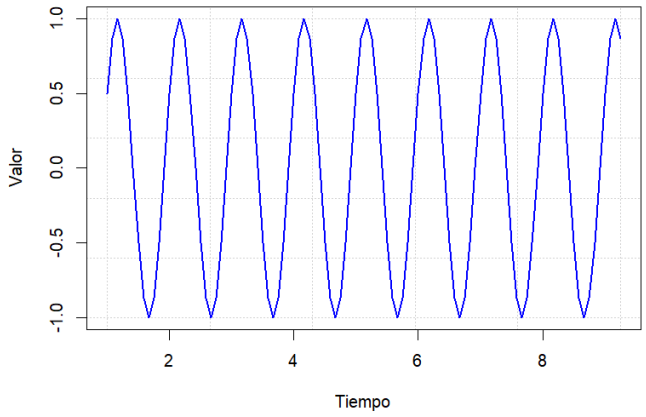


Figura 2: Ejemplo de una serie de tiempo.

Una serie estacionaria no necesariamente tiene que ser constante; puede presentar fluctuaciones alrededor de una media aproximadamente constante.

¿Por qué nos interesa la estacionariedad?

Muchos modelos de series de tiempo se construyen bajo el supuesto de estacionariedad. Si una serie presenta una tendencia estocástica, trabajar directamente con ella puede producir relaciones engañosas. Una herramienta fundamental es la raíz unitaria. Consideremos:

$$Y_t = \phi Y_{t-1} + \epsilon_t$$

donde

$$\epsilon_t \sim WN(0, \sigma^2)$$

El proceso es estacionario si $|\phi| < 1$. Si $\phi = 1$, tenemos

$$Y_t = Y_{t-1} + \epsilon_t$$

que corresponde a una caminata aleatoria y contiene una raíz unitaria.

La prueba de raíz unitaria

La idea básica es evaluar

$$H_0 : \phi = 1$$

contra

$$H_1 : \phi < 1$$

Partimos de

$$Y_t = \phi Y_{t-1} + \epsilon_t$$

y restando Y_{t-1} de ambos lados:

$$\Delta Y_t = (\phi - 1) Y_{t-1} + \epsilon_t$$

Definimos $\gamma = \phi - 1$; entonces

$$\Delta Y_t = \gamma Y_{t-1} + \epsilon_t$$

y la hipótesis de raíz unitaria es

$$H_0 : \gamma = 0$$

Prueba Dickey-Fuller aumentada

La prueba ADF incorpora rezagos de las diferencias:

$$\Delta Y_t = \alpha + \beta t + \gamma Y_{t-1} + \sum_{i=1}^{p} \delta_i \Delta Y_{t-i} + \epsilon_t$$

Dependiendo del modelo, podemos incluir:

- Sin constante ni tendencia
- Constante
- Constante y tendencia (es decir, qué tanta pendiente tiene)

Hipótesis:

$$H_0 : \gamma = 0$$

$$H_1 : \gamma < 0$$

Si rechazamos H_0, existe evidencia contra la presencia de una raíz unitaria.
Importante: interpretar correctamente la ADF
La hipótesis nula de la ADF es que existe raíz unitaria; por tanto:

Resultado	**Interpretación**
No rechazar H_0	Evidencia compatible con raíz unitaria
Rechazar H_0	Evidencia contra raíz unitaria

No debemos decir:

$$p > 0{,}05 \rightarrow \text{la serie tiene raíz unitaria}$$

Lo correcto es:

$$p > 0{,}05 \rightarrow \text{no tenemos evidencia suficiente para rechazar la raíz unitaria}$$

Del mismo modo, $p < 0{,}05$ da evidencia contra la raíz unitaria, pero no demuestra que la serie sea estacionaria.

ADF en RStudio

Una implementación frecuente utiliza el paquete `tseries`:

```
library(tseries)
adf.test(y)
```

Para analizar la serie diferenciada:

```
dy = diff(y)
adf.test(dy)
```

También podemos utilizar otras especificaciones de la prueba mediante paquetes especializados. La idea es pasar de

$$Y_t \to \Delta Y_t$$

si la evidencia sugiere que la serie original tiene una raíz unitaria.

Otras pruebas de estacionariedad

La prueba ADF no es la única prueba.

Phillips-Perron (PP) Tiene como hipótesis nula:

$$H_0 : \text{raíz unitaria}$$

KPSS Tiene una hipótesis nula diferente:

$$H_0 : \text{estacionariedad}$$

Esto permite utilizar las pruebas de manera complementaria.

Prueba	**Hipótesis nula**
ADF	Raíz unitaria
PP	Raíz unitaria
KPSS	Estacionariedad

¿Qué hacemos si la serie no es estacionaria? Una estrategia común es diferenciar:

$$\Delta Y_t = Y_t - Y_{t-1}$$

Si una diferencia es suficiente, ΔY_t puede ser estacionaria; si no es suficiente:

$$\Delta^2 Y_t = \Delta(\Delta Y_t)$$

El número de diferencias necesarias se representa mediante d en un modelo $ARIMA(p, d, q)$. Por ejemplo,

$$Y_t \to \Delta Y_t$$

significa $d = 1$.

Una vez estacionaria, ¿qué sigue? Supongamos que tenemos una serie estacionaria, Y_t. Ahora queremos determinar su estructura de dependencia temporal. Dos modelos fundamentales son el $AR(p)$ y el $MA(q)$; al combinarlos se forma un $ARMA(p,q)$, y si la serie tuvo que diferenciarse d veces para volverse estacionaria, se obtiene un $ARIMA(p,d,q)$. Las herramientas principales para identificar los rezagos serán la función de autocorrelación (ACF) y la función de autocorrelación parcial (PACF).

¿Cómo se lee la ACF? La ACF se representa con una gráfica llamada correlograma (Figura 3). En el eje x se encuentra k, que es el rezago, es decir, cuántos periodos hacia atrás se compara la serie. En el eje y se encuentra ρ_k, que es la autocorrelación en el rezago k: qué tanto se relaciona la serie con ella misma desplazada k periodos. Por ejemplo, ρ_2 indica qué tanto se relaciona cada valor Y_t con el valor de dos periodos antes, Y_{t-2}. En el rezago $k = 0$ siempre se cumple que $\rho_0 = 1$, ya que la serie se compara consigo misma.

Los valores de ρ_k van de -1 a 1, por lo que puede haber correlaciones negativas. Para cada rezago hay tres opciones:

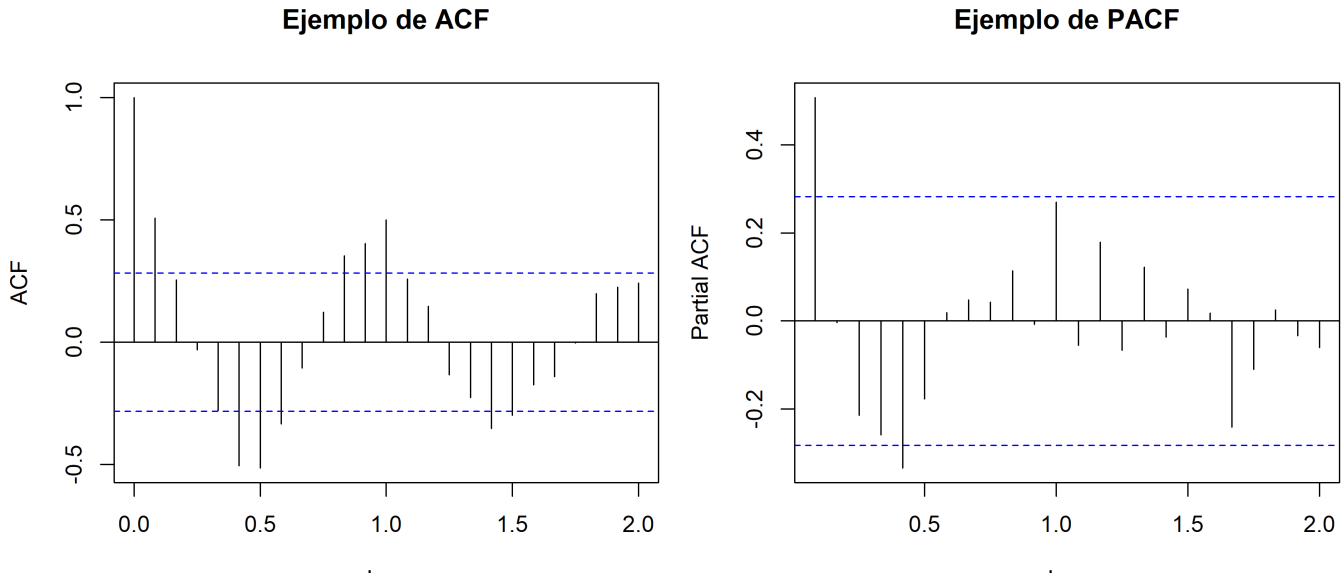
- $\rho_k > 0$: la serie se relaciona en la misma dirección con su valor de k periodos atrás; si antes fue alto, ahora tiende a ser alto.
- $\rho_k = 0$: no hay relación con ese rezago.
- $\rho_k < 0$: la serie se relaciona en dirección contraria; si antes fue alto, ahora tiende a ser bajo.

Además, el correlograma muestra dos líneas punteadas que representan los límites de significancia. Las barras que cruzan estos límites corresponden a autocorrelaciones significativas, mientras que las que quedan dentro pueden deberse al azar.

¿Y la PACF? La PACF se lee igual que la ACF, pero mide algo distinto. En la ACF, la relación con el rezago 2 incluye también el efecto que pasa a través del rezago 1. La PACF elimina ese efecto intermedio y mide solo la relación directa entre Y_t y Y_{t-k}.

Con ambas gráficas se identifica el modelo:

- En un $AR(p)$, la PACF se corta después del rezago p y la ACF decae poco a poco.
- En un $MA(q)$, la ACF se corta después del rezago q y la PACF decae poco a poco.



Función de autocorrelación (ACF) La función de autocorrelación de orden k es

$$\rho_k = \frac{\text{Cov}(Y_t, Y_{t-k})}{\sqrt{\text{Var}(Y_t)\,\text{Var}(Y_{t-k})}}$$

Para una serie estacionaria, la varianza es la misma en todo momento, es decir, $\text{Var}(Y_t) = \text{Var}(Y_{t-k}) = \nu_0$, por lo que la fórmula se simplifica a

$$\rho_k = \frac{\nu_k}{\nu_0}$$

donde $\nu_k = \text{Cov}(Y_t, Y_{t-k})$ es la autocovarianza en el rezago k y ν_0 es la varianza de la serie.

La función de autocorrelación (ACF) mide la relación entre Y_t y Y_{t-k}; por ejemplo:

$$\rho_1 = \text{Corr}(Y_t, Y_{t-1})$$

$$\rho_2 = \text{Corr}(Y_t, Y_{t-2})$$

Autocorrelación parcial (PACF) La PACF mide la relación entre Y_t y Y_{t-k} después de controlar por los rezagos intermedios. Por ejemplo, la PACF de orden 2 mide la relación entre Y_t y Y_{t-2}, controlando por Y_{t-1}. La diferencia fundamental es:

$$\text{ACF} \rightarrow \text{correlación total}$$

$$\text{PACF} \rightarrow \text{correlación parcial}$$

Modelo autorregresivo AR(1) Un modelo AR(1) tiene la forma

$$Y_t = c + \phi_1 Y_{t-1} + \epsilon_t$$

El valor actual depende de Y_{t-1}, más un término aleatorio. Si $|\phi_1| < 1$, el proceso AR(1) es estacionario. Podemos escribir

$$Y_t = \phi_1 Y_{t-1} + \epsilon_t$$

y observar que el efecto de un shock se transmite hacia el futuro:

$$\epsilon_t \rightarrow Y_t \rightarrow Y_{t+1} \rightarrow Y_{t+2} \rightarrow \dots$$

Modelo AR(p) Un modelo AR(p) es:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \epsilon_t$$

En forma compacta:

$$Y_t = c + \sum_{i=1}^{p} \phi_i Y_{t-i} + \epsilon_t$$

La pregunta es: **¿cómo elegimos p?** Una herramienta fundamental es la PACF.

Identificación de un AR mediante ACF y PACF Para un proceso AR(p), típicamente:

- La PACF se corta aproximadamente después del rezago p.
- La ACF decrece gradualmente.

Un patrón típico:

Cuadro 2: Ejemplo de identificación de un modelo con la ACF y la PACF.

Rezago	**1**	**2**	**3**	**4**	**5**	**6**
PACF	$*$	$*$				
ACF	$*$	$*$	$*$	$*$		

$*$: autocorrelación significativa.

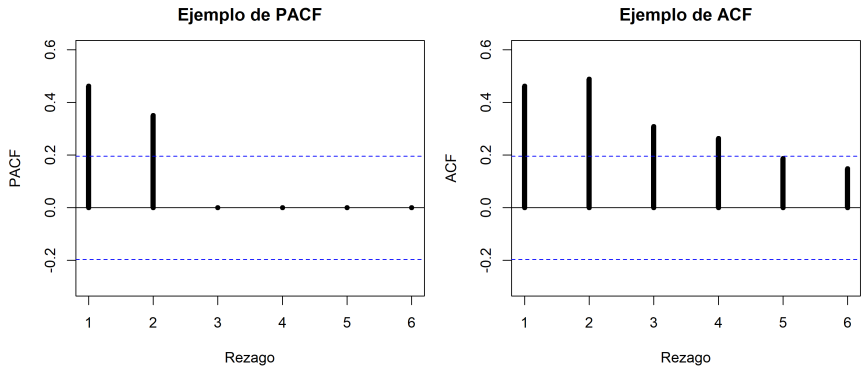


Figura 4: ACF y PACF teóricas de un modelo AR(2).

En la Figura 4 se observa el comportamiento descrito en la Tabla 2: la PACF solo es significativa en los rezagos 1 y 2, mientras que la ACF es significativa en los rezagos 1 a 4 y disminuye poco a poco. Este patrón indica que la serie depende directamente de sus dos valores anteriores, por lo que se identifica un modelo AR(2).

ACF y PACF en R En R, la ACF y la PACF se obtienen con las funciones `acf()` y `pacf()`:

```
acf(y, lag.max = 5, main = "Funcion de autocorrelacion")   # el 5 es el rezago maximo
pacf(y, main = "Funcion de autocorrelacion parcial")
```

donde `y` es la serie de tiempo, `lag.max` indica hasta qué rezago se calcula y `main` es el título de la gráfica.

Los límites de confianza ayudan a identificar autocorrelaciones que son estadísticamente diferentes de cero. Sin embargo, la ACF y la PACF sirven para identificar candidatos, no para decidir automáticamente el modelo final.

Modelo de medias móviles MA(1) Un modelo MA(1) tiene la forma

$$Y_t = \mu + \epsilon_t + \theta_1 \epsilon_{t-1}$$

El valor actual depende de:

- Un shock actual, ϵ_t.
- El shock ocurrido en el periodo anterior, ϵ_{t-1}.

A diferencia del AR, que depende de valores pasados de Y, el MA depende de errores pasados ϵ_{t-k}.

Modelo MA(q) Un modelo MA(q) es de la forma

$$Y_t = \mu + \epsilon_t + \theta_1\epsilon_{t-1} + \theta_2\epsilon_{t-2} + \cdots + \theta_q\epsilon_{t-q}$$

La pregunta es: ¿cómo identificamos q? La herramienta principal es la ACF. Para un MA(q), típicamente:

- La ACF se corta después del rezago q.
- La PACF decrece gradualmente.

Identificación de un MA Supongamos que observamos:

Cuadro 3: Ejemplo de identificación de un modelo MA con la ACF y la PACF.

Rezago	**1**	**2**	**3**	**4**	**5**	**6**
ACF	$*$	$*$	$*$			
PACF	$*$	$*$	$*$	$*$		

$*$: autocorrelación significativa.

En este caso, la ACF es significativa solo en los rezagos 1 a 3 y después se corta, mientras que la PACF decae gradualmente. Este patrón indica que la serie depende de los errores de sus tres periodos anteriores, por lo que se identifica un modelo MA(3). Una regla práctica es:

Cuadro 4: Regla práctica para identificar p y q con la ACF y la PACF.

	ACF	**PACF**
AR(p)	Decae	Se corta en p
MA(q)	Se corta en q	Decae

¿Qué significa que se corta? En la práctica, la ACF o la PACF no necesariamente se vuelven exactamente cero. Observamos si los coeficientes posteriores al rezago candidato se encuentran aproximadamente dentro de las bandas de confianza. Por ejemplo, si

$$\rho_1 \neq 0, \quad \rho_2 \neq 0, \quad \rho_3 \neq 0$$

pero $\rho_4, \rho_5, \ldots$ no son estadísticamente diferentes de cero, entonces podemos considerar un $MA(3)$. La identificación mediante ACF y PACF es una herramienta de diagnóstico, no una regla determinista.

ARMA: combinar AR y MA Si la serie es estacionaria, podemos combinar ambos componentes en un $ARMA(p, q)$. Por ejemplo, un $ARMA(1, 1)$:

$$Y_t = c + \phi_1 Y_{t-1} + \epsilon_t + \theta_1 \epsilon_{t-1}$$

En general:

$$Y_t = c + \sum_{i=1}^{p} \phi_i Y_{t-i} + \epsilon_t + \sum_{j=1}^{q} \theta_j \epsilon_{t-j}$$

Pero, ¿qué podemos hacer si la serie original no es estacionaria?

Modelo ARIMA ¿Qué significa $ARIMA(p, d, q)$? Donde:

- p: número de rezagos del componente autorregresivo.
- d: número de diferencias.
- q: número de rezagos del componente de medias móviles.

La lógica es:

Serie original

$\downarrow$

Diferenciar d veces

$\downarrow$

Serie estacionaria

$\Downarrow$

ARMA(p, q)

¿Cómo identificamos un ARIMA? La identificación se realiza en tres etapas:

1. d: determinar cuántas diferencias son necesarias.
2. p: analizar la PACF de la serie estacionaria.
3. q: analizar la ACF de la serie estacionaria.

Por ejemplo, si ΔY_t es estacionaria, entonces $d = 1$; si su PACF sugiere $p = 2$ y su ACF sugiere $q = 1$, entonces se tiene un $ARIMA(2, 1, 1)$.

Modelo SARIMA: la parte estacional Cuando la serie tiene un patrón que se repite cada cierto número de periodos (por ejemplo, cada 12 meses en datos mensuales), el ARIMA se extiende con una parte estacional. A este modelo se le llama SARIMA y se escribe

$$SARIMA(p, d, q)(P, D, Q)_s$$

donde (p, d, q) es la parte que ya conocemos, que compara con los periodos inmediatamente anteriores, y (P, D, Q) es la parte estacional, que hace lo mismo pero comparando con el mismo periodo de ciclos anteriores. El subíndice s indica la longitud del ciclo; en datos mensuales, $s = 12$:

- P: número de rezagos autorregresivos estacionales (usa el valor del mismo mes de años anteriores).
- D: número de diferencias estacionales; por ejemplo, $D = 1$ significa trabajar con $Y_t - Y_{t-12}$.
- Q: número de rezagos de medias móviles estacionales (usa el error del mismo mes de años anteriores).

En R, la función `auto.arima()` incorpora esta parte estacional cuando la serie se define con `frequency = 12`, y la escribe como `ARIMA(p,d,q)(P,D,Q)[12]`.

Identificación mediante ACF y PACF Una guía inicial:

Cuadro 5: Comportamiento de las funciones ACF y PACF.

Modelo	**ACF**	**PACF**
AR(p)	Decrecimiento gradual	Se corta en p
MA(q)	Se corta en q	Decrecimiento gradual
ARMA(p, q)	Decrecimiento gradual	Decrecimiento gradual

Para un ARIMA, aplicamos la ACF y la PACF después de diferenciar, cuando las diferencias han producido una serie aproximadamente estacionaria.

Problema: varios modelos Supongamos que la ACF y la PACF sugieren un $ARIMA(1,1,1)$, pero también un $ARIMA(2,1,1)$ y un $ARIMA(1,1,2)$. Entonces, ¿cuál debemos utilizar? No necesariamente existe un único modelo evidente. Por ello necesitamos **criterios de selección** y, posteriormente, **diagnóstico de residuos**.

Criterios de información Dos criterios utilizados frecuentemente son:

$$\text{AIC} = -2\log(L) + 2k$$

$$\text{BIC} = -2\log(L) + k\log(n)$$

donde:

- L: función de verosimilitud.
- k: número de parámetros estimados.
- n: número de observaciones.

Ambos penalizan a los modelos con demasiados parámetros. Para comparar modelos:

$$\text{menor AIC/BIC} \rightarrow \text{mejor modelo según el criterio}$$

AIC vs. BIC El **AIC** penaliza la complejidad mediante $\mathbf{2}\boldsymbol{k}$ y el **BIC** mediante $\boldsymbol{k}\,\mathbf{log}(\boldsymbol{n})$. Cuando n es suficientemente grande, $\log(n) > 2$; por lo tanto, el BIC suele imponer una penalización mayor por agregar parámetros. Esto puede producir diferentes modelos seleccionados: el modelo A puede tener menor AIC, pero el modelo B menor BIC. No existe una regla universal que obligue a utilizar únicamente uno de ellos.

AICc: el AIC corregido Cuando la serie tiene pocas observaciones, el AIC tiende a preferir modelos demasiado complejos. Para corregirlo se utiliza el AICc:

$$\text{AICc} = \text{AIC} + \frac{2k(k+1)}{n-k-1}$$

La corrección es mayor mientras más pequeña sea la muestra, y cuando n es muy grande, el AICc se parece al AIC. La función `auto.arima()` utiliza el AICc por defecto para elegir el modelo.

Comparar modelos en R Podemos estimar diferentes modelos en R:

```
library(forecast)
m1 = Arima(y, order = c(1, 1, 1))
m2 = Arima(y, order = c(2, 1, 1))
m3 = Arima(y, order = c(1, 1, 2))
AIC(m1, m2, m3)
BIC(m1, m2, m3)
```

Pero un menor AIC no garantiza un buen modelo Supongamos que $\text{AIC}(m_1) < \text{AIC}(m_2)$. Esto indica que m_1 tiene un mejor compromiso entre ajuste y complejidad según el AIC. Pero todavía debemos preguntar:

¿Los residuos se comportan como ruido blanco?

Un buen modelo debe haber capturado la estructura sistemática de la serie. Por lo tanto:

$$\text{selección} \neq \text{únicamente AIC/BIC}$$

Diagnóstico de residuos Definimos los residuos como

$$\hat{\epsilon}_t = Y_t - \hat{Y}_t$$

Queremos que los residuos se parezcan a una distribución normal con media cero:

$$N(0, \sigma^2)$$

es decir:

- Media aproximadamente 0.
- Varianza aproximadamente constante.
- Sin autocorrelación.

La propiedad fundamental es

$$\text{Corr}(\hat{\epsilon}_t, \hat{\epsilon}_{t-k}) \approx 0$$

para los principales rezagos.

ACF de los residuos Una herramienta sencilla es graficar la ACF de $\hat{\epsilon}_t$. Si observamos autocorrelaciones significativas, $\hat{\rho}_k \neq 0$, podría existir estructura temporal que el modelo no ha capturado. Por tanto,

una ACF de residuos sin autocorrelación significativa

es evidencia favorable para el modelo.

No debemos confundir la ACF de la serie, ACF(Y_t), con la ACF de los residuos, ACF$(\hat{\epsilon}_t)$.

Prueba de Ljung-Box La prueba de Ljung-Box permite evaluar conjuntamente las autocorrelaciones de los residuos. Hipótesis:

$$H_0 : \rho_1 = \rho_2 = \cdots = \rho_k = 0$$

Alternativa:

$$H_1 : \text{al menos una autocorrelación es diferente de cero}$$

Si el p-valor es mayor que 0.05, no rechazamos H_0; esto es consistente con residuos sin autocorrelación significativa. Si el p-valor es menor que 0.05, existe evidencia de autocorrelación remanente.

Ljung-Box en R

```
Box.test(residuals(m1), lag = 12, type = "Ljung-Box")
```

También podemos utilizar:

```
checkresiduals(m1)
```

Esta función permite observar:

- Los residuos.
- La ACF de los residuos.
- La prueba de Ljung-Box.

Normalidad de los residuos En algunos contextos también se analiza si

$$\hat{\epsilon}_t \sim N(0, \sigma^2)$$

Podemos utilizar:

- Histograma.
- Gráfica Q-Q.
- Pruebas de normalidad.

Sin embargo, para muchos objetivos de pronóstico:

> La ausencia de autocorrelación es más importante que la normalidad exacta.

La normalidad puede ser especialmente relevante para ciertos intervalos y procedimientos inferenciales.

Identificación automática También podemos utilizar procedimientos automáticos:

```
library(forecast)
modelo = auto.arima(y)
modelo
```

La función explora diferentes combinaciones de (p, d, q) y puede incorporar componentes estacionales. Pero:

> `auto.arima()` no sustituye el análisis estadístico.

Es importante comprender por qué el algoritmo seleccionó determinado modelo.

¿Cómo decide el modelo automático? De manera simplificada, un procedimiento automático puede:

1. Evaluar transformaciones y diferenciación.
2. Probar diferentes valores de p y q.
3. Estimar los modelos candidatos.
4. Comparar criterios de información.
5. Seleccionar un modelo según el criterio utilizado.

La interpretación sigue dependiendo del investigador:

> algoritmo + diagnóstico + conocimiento del problema

Errores al hacer el análisis

- Estimar un ARIMA sin revisar la estacionariedad.
- Utilizar demasiados rezagos.
- Elegir únicamente por R^2.
- Elegir únicamente por AIC.
- No revisar los residuos.
- Confundir una serie con tendencia con una serie estacionaria.
- Interpretar "no rechazarçomo "demostrar.estacionariedad.

Regresión lineal múltiple

¿Qué es una regresión lineal múltiple?

Una regresión lineal múltiple busca explicar una variable de interés, llamada variable respuesta Y, a partir de varias variables explicativas $X_1, X_2, \ldots, X_p$:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon$$

donde:

- Y: variable respuesta, la que queremos explicar o predecir.
- $X_1, \ldots, X_p$: variables explicativas.
- β_0: intercepto.
- $\beta_1, \ldots, \beta_p$: coeficientes de cada variable.
- ϵ: error aleatorio, lo que el modelo no logra explicar.

¿Cómo se estiman los coeficientes? Los coeficientes se estiman por **mínimos cuadrados ordinarios**, que buscan los valores de β que hacen más pequeña la suma de los errores al cuadrado:

$$\min_{\beta} \sum_{i=1}^{n} \left(Y_i - \hat{Y}_i\right)^2$$

donde $\hat{Y}_i$ es el valor que predice el modelo para la observación i. Los errores se elevan al cuadrado para que los positivos y los negativos no se cancelen.

Regresión en R En R, la regresión se ajusta con la función `lm()`. A la izquierda de ~ va la variable respuesta y a la derecha, las explicativas:

```
modelo = lm(y ~ x1 + x2 + x3, data = datos)
summary(modelo)
```

La función `summary()` muestra los coeficientes, sus p-valores y el R^2 del modelo.

¿Cómo se interpreta un coeficiente?

El coeficiente β_j indica cuánto cambia Y, en promedio, cuando X_j aumenta en una unidad, manteniendo constantes las demás variables:

- $\beta_j > 0$: cuando X_j aumenta, Y tiende a aumentar.
- $\beta_j < 0$: cuando X_j aumenta, Y tiende a disminuir.

Un coeficiente siempre se interpreta tomando en cuenta las demás variables del modelo

¿La variable es significativa? Para cada coeficiente se realiza la prueba:

$$H_0 : \beta_j = 0$$

contra

$$H_1 : \beta_j \neq 0$$

Si el p-valor es menor que 0.05, rechazamos H_0: hay evidencia de que la variable aporta información para explicar Y.

Correlación de Spearman

Antes de construir el modelo conviene revisar qué tan relacionadas están las variables. La correlación de Spearman mide la relación entre dos variables usando el orden de sus valores, por lo que detecta relaciones aunque no sean exactamente lineales. Igual que la autocorrelación, va de -1 a 1:

- Cerca de 1: cuando una variable aumenta, la otra también.
- Cerca de 0: no hay relación.
- Cerca de -1: cuando una variable aumenta, la otra disminuye.

Correlación en R

```
cor(datos, method = "spearman")
```

Para verla de forma gráfica, podemos utilizar un mapa de calor con el paquete `corrplot`:

```
library(corrplot)
corrplot(cor(datos, method = "spearman"), method = "color")
```

Multicolinealidad

Se presenta cuando dos o más variables explicativas están muy correlacionadas entre sí, es decir, dicen casi lo mismo. En ese caso, el modelo no sabe a cuál de ellas atribuirle el efecto sobre Y, y los coeficientes se vuelven inestables: pueden cambiar mucho al quitar algunas observaciones o salir con signos que no tienen sentido.

Si dos variables están muy correlacionadas, conviene conservar solo una

Selección de variables paso a paso

No todas las variables aportan información al modelo. La pregunta es: **¿cuáles dejamos?** El procedimiento paso a paso (*stepwise*) agrega o quita variables una por una, y en cada paso se queda con el modelo de menor AIC:

$$\text{AIC} = -2\log(L) + 2k$$

Se detiene cuando ningún cambio disminuye el AIC. Así se busca un modelo que se ajuste bien a los datos sin ser innecesariamente complicado.

Selección paso a paso en R

```
modelo_final = step(modelo)
summary(modelo_final)
```

Diagnóstico de residuos

Los residuos son la diferencia entre el valor real y el predicho:

$$\hat{e}_i = Y_i - \hat{Y}_i$$

Igual que en series de tiempo, queremos que se comporten como ruido:

- Media aproximadamente 0.
- Varianza aproximadamente constante.
- Distribución aproximadamente normal.

Residuos en R

```
plot(modelo_final, which = c(1, 2))
```

Esta función muestra dos gráficas:

- **Residuos contra valores ajustados:** los puntos deben estar regados alrededor de cero, sin formar curvas ni un embudo.
- **Gráfica Q-Q:** los puntos deben seguir la línea diagonal.

Validación cruzada

Un modelo puede ajustarse muy bien a los datos con los que se construyó, pero predecir mal datos nuevos. Por lo tanto:

> Un buen ajuste no garantiza una buena predicción

Para saber qué tan bien predice datos que no vio, se usa la validación cruzada de k grupos:

1. Los datos se dividen al azar en k grupos.
2. Se ajusta el modelo con $k-1$ grupos y se predice el grupo que quedó fuera.
3. Se repite k veces, hasta que cada grupo se predijo una vez.
4. Con todas las predicciones se calculan las métricas de error.

Como la división en grupos es al azar, se fija una **semilla** para que los grupos salgan iguales cada vez que se repite el análisis, y así los resultados se puedan reproducir.

Validación cruzada en R Por ejemplo, con $k = 5$:

```
set.seed(123)
grupo = sample(rep(1:5, length.out = nrow(datos)))
pred = numeric(nrow(datos))

for (g in 1:5) {
  m = lm(formula(modelo_final), data = datos[grupo != g, ])
  pred[grupo == g] = predict(m, newdata = datos[grupo == g, ])
}
```

Métricas de error

Para comparar los valores reales Y_i con los predichos $\hat{Y}_i$ se usan:

Raíz del error cuadrático medio (RMSE)

$$\text{RMSE} = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}$$

Está en las mismas unidades que Y y castiga más los errores grandes.

Error absoluto medio (MAE)

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}\left|Y_i - \hat{Y}_i\right|$$

Es el error promedio, sin importar si el modelo se pasó o se quedó corto.

Coeficiente de determinación (R^2)

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(Y_i - \hat{Y}_i)^2}{\sum_{i=1}^{n}(Y_i - \bar{Y})^2}$$

Indica qué proporción de la variabilidad de Y explica el modelo; va de 0 a 1.

Para comparar modelos:

$$\text{menor RMSE y MAE, y } R^2 \text{ más cercano a 1} \rightarrow \text{mejor modelo}$$

Métricas en R Con las predicciones de la validación cruzada:

```
rmse = sqrt(mean((datos$y - pred)^2))
mae  = mean(abs(datos$y - pred))
r2   = 1 - sum((datos$y - pred)^2) / sum((datos$y - mean(datos$y))^2)
```

Predecir datos nuevos Una vez elegido y validado el modelo, podemos predecir:

```
predict(modelo_final, newdata = datos_nuevos)
```

Intervalo de predicción Además del valor predicho, podemos obtener un intervalo donde esperamos que caiga el valor real con cierta confianza, por ejemplo 95 %. El intervalo es más ancho cuando el modelo tiene más error.

```
predict(modelo_final, newdata = datos_nuevos, interval = "prediction", level = 0.95)
```

Esta función regresa el valor predicho (`fit`) y los límites inferior (`lwr`) y superior (`upr`) del intervalo.

Metodologia

Extraccion de datos

Los datos de precipitacion, temperatura minima y maxima, elevacion y pendiente venian en archivos .tif, son imagenes donde viene informacion que uno puede extraer la información para obtener el valor de cada parcela se usó el paquete `terra` de R junto con el archivo *shapefile* de las parcelas, que contiene el poligono de cada una con la funcion `extract` se obtuvo el valor de cada variable dentro de cada poligono, para cada mes del 2022 al 2025.

De esta forma se obtuvo una base por variable, con una fila por parcela y por mes. En el caso de la topografía, como la elevacion y la pendiente no cambian con el tiempo se obtuvo un solo valor por parcela, a esta base se le agregaron tambien el municipio y estado por parcela. Cabe mencionar que, en la parte de extracción de datos, se usó IA para poder guiarnos, ya que sabemos pasar de una base de datos a una imagen con información (por ejemplo, un mapa de población), pero no al revés, al tratar de extraer los datos de las imágenes se nos dificultó y le pedimos ayuda a la IA ya que en R se puede hacer de todo.

Regularización de las series

Para poder hacer el análisis de series de tiempo se necesita que la base sea regular y que los datos estén igual de espaciados. Regular es que no haya huecos, por así decirlo, que tenga un dato por mes; que estén igual de espaciados es que, si tengo 5 datos en un mes, solo haya uno, ya que R no distingue fechas: si en un mes hay 5 datos, los toma como si fueran 5 meses distintos. Por ello, al hacer el filtro de nubosidad (solo tomamos un porcentaje de nubosidad menor que el 20 por ciento), hubo meses que tenían varios datos y otros donde ya no. Por eso mismo se calculó la mediana de cada índice por mes (en los meses donde había más de un dato y por parcela). Se usó la mediana en lugar del promedio, ya que se ve menos afectada por los valores atípicos que hay por mes (se hizo un boxplot por mes). Después, se completaron los meses que no tenían ninguna imagen y esos vacíos se rellenaron con interpolación lineal, usando la función `na.approx()` del paquete `zoo`, que estima el valor faltante a partir de los meses de antes y de después; es como si tuvieras una función que no es continua, pero la vuelves continua uniendo los puntos con líneas rectas.

Selección de variables y limpieza

Al leer las dos bases de datos donde vienen los índices satelitales, se leyeron de principio a fin y venía una variable que es el porcentaje de nubosidad. Esta variable nos dice que tantas nubes hubo cuando se tomaron los datos: mientras más grande sea el porcentaje de nubes, la información es menos precisa, y si el porcentaje es 100 por ciento, no habrá información en esa fecha. Por eso mismo se hizo un filtro en R usando la librería `dplyr`, donde usamos la función `filter()` y le pedimos que el porcentaje de nubes fuera menor que el 20 por ciento.

Al iniciar un análisis de series de tiempo, se requiere trabajar con un número reducido de variables debido a la rigurosidad del proceso. Trabajar con demasiadas variables vuelve el análisis complejo y tedioso; por ello, de las 96 variables disponibles en la base de datos `BASICO`, se seleccionaron solo tres. Esta elección se basó en su significado agronómico y en el nivel de comprensión técnica de las mismas. Las variables seleccionadas, que proceden exclusivamente del sensor Sentinel-2, ya fueron mencionadas en el marco teórico y dieron origen a la base de datos denominada `BASICO_seleccion`.

Un procedimiento similar se aplicó a la base `PRO`. No obstante, al contar con menos variables y disponer únicamente de datos del año 2025, no se realizó un análisis de series de tiempo en esta etapa. A pesar de esto, se llevaron a cabo los demás procesos, como el filtro por porcentaje de nubes y la selección del índice según su relevancia agronómica. Para esta base se eligió únicamente el índice EVI (el mismo que en `BASICO`). Es fundamental no confundir ni fusionar estas bases, ya que provienen de dos sensores diferentes. A este segundo subconjunto se le denominó `PRO_seleccion`.

Análisis de series de tiempo

El análisis de series de tiempo se aplicó a seis variables, las cuales fueron:

- Precipitación
- Temperatura mínima
- Temperatura máxima
- EVI
- MSI
- NDSVI

todas con un dato por mes del 2022 al 2025. Como cada parcela tiene su propia serie, el análisis se hizo para cada una de las 197 parcelas; como son muchas series y es poco el tiempo, decidimos usar un ciclo `for` en R.

Para cada una de las variables se aplicó lo mismo:

1. Se convirtieron los datos en series de tiempo con la función `ts()`, diciendo que son datos mensuales (`frequency = 12`).
2. Se graficaron las series de todas las parcelas en un mismo gráfico, usando `matplot()`, para ver su comportamiento.
3. Se obtuvieron la ACF y la PACF con las funciones `acf()` y `pacf()`, para ver si los valores de un mes se relacionan con los de meses anteriores.
4. Se hicieron pruebas de estacionariedad para ver si las series son estacionarias, con tres pruebas: Dickey-Fuller aumentada, KPSS y Phillips-Perron. Se usaron las tres, ya que cada una tiene una hipótesis distinta; si las tres coinciden, podemos asegurar más que sí es estacionaria.
5. Se ajustó un modelo a cada serie con la función `auto.arima()` del paquete `forecast`, que prueba varios modelos ARIMA y SARIMA y se queda con el de menor AICc. Se usó `auto.arima()` por cuestiones de tiempo, ya que no estaríamos haciendo el análisis estadístico de cada una de las 197 parcelas por las 6 variables.
6. Se revisaron los residuos de los modelos con la prueba de Ljung-Box, para comprobar que se comportan como ruido y que el modelo haya capturado la información de la serie.

Como son 197 parcelas por variable, los resultados se guardaron en una tabla y se resumieron con histogramas y tablas de frecuencias, para ver qué comportamiento tenía la mayoría de las parcelas.

Ubicaciones de las etapas fenologicas

Como se menciono en el marco teorico, usamos una escala para tener conocimiento de las etapas fenologicas de la cebada, la cual fue la escala zadoks, esta escala no dice los meses que sucede cada etapa, para ello se nos ocurrió usar el EVI de planet, ya que son datos del 2025, años donde se sembró y se cosecho la cebada, ademas notamos que tiene imagenes casi diarias aun aplicando el filtro de nubosidad.

Se grafico la curva del EVI a lo largo del ciclo, usando la mediana de las 197 parcelas en cada fecha. La idea es que el EVI nos dice que tan verde esta nuestra cultivo, cuando la planta aun es pequeña el EVI es bajo pero cuando la planta esta creciendo el EVI tiende a crecer tambien y se llega a su punto maximo cuando la planta esta muy verde ya bien desarrollada, baja cuando la planta va madurando y se va secando para despues su cosecha.

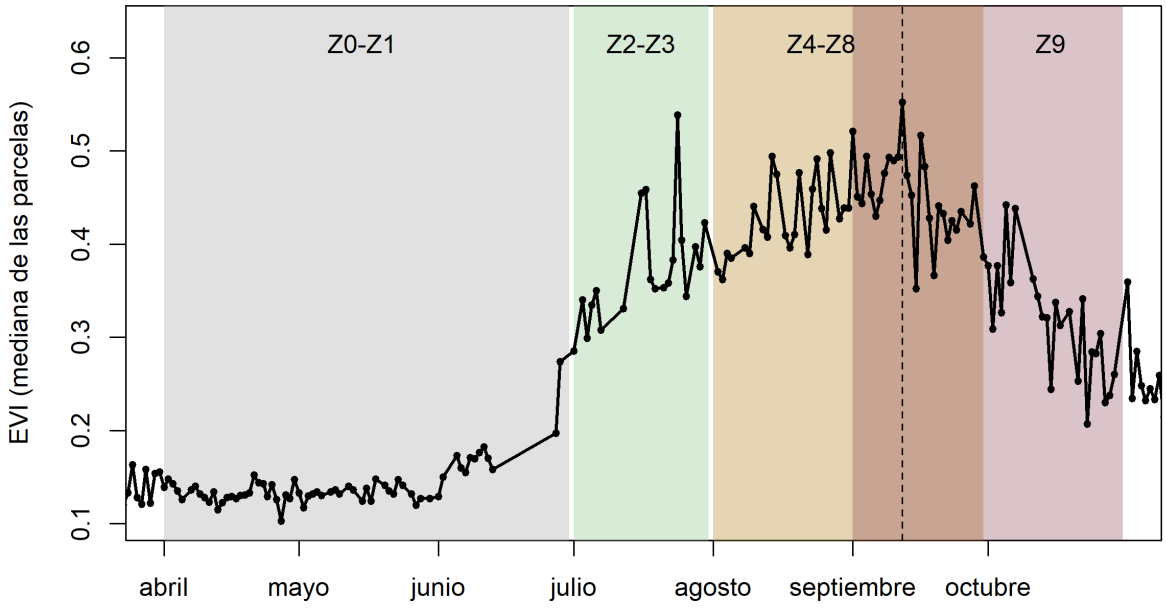


Figura 5: Curva del EVI de Planet en 2025 (mediana de las 197 parcelas) y ubicación de las etapas fenológicas de la escala de Zadoks. La línea punteada marca el máximo del EVI, eso segun la grafica.

Con base en esa curva, las etapas se ubicaron asi:

- Germinacion y salen primeras hojas (Z0-Z1): abril a junio, cuando el EVI todavia es bajo y el cultivo casi no se ve desde el satelite.

- Formacion de nuevos tallos y creciemiento de estos mismo (Z2-Z3): julio, cuando el EVI empieza a subir
- Sale espiga, florece y se empieza a llenar el grano (Z4-Z8): agosto-septiembre, aqui es donde aproximadamente esta su EVI máximo, que se alcanzó alrededor de septiembre
- Madurez del grano (Z9): de septiebre-octubre, cuando el EVI baja porque la planta se empieza a secar, ya no es tan verde.

Estos periodos se usaron despues para consstruir las variables del modelo por etapa.

Construccion de las variables

Recordemos que el analisis de series de tiempo no se usó para predecir directamenete el rendimiento, si no para entender como se comporta cada variable a lo largo de la temporada, y se aprovecho de forma diferente según cada variable. En el caso de la variable precipitacion, mostró que la lluvia de un mes se relaciona con la del mismo mes de años anteriores, por eso se construyó la anomalía de la lluvia, que compara la lluvia del 2025 con la de los años anteriores del 2022-2024. En el caso de los índices satelitales, para la mayoria de las parcelas el modelo que dio `auto.arima` tuvo una parte estacional de 12 meses, es decir, el EVI, el MSI y el NDSVI suben y bajan cada año en los mismos meses siguiendo el ciclo del cultivo. Por eso no tenia sentido usar el valor del mes anterior para explicar el rendimiento, si no medir cada índice conforme a su etapa fenológica donde es mas importante, cabe aclarar que los periodos de cada etapa se definieron con la escala de zadoks y la curva de EVI planet. También, las bases que se regularizaron se construyeron para el análisis de series se usaron para calcular el MSI y el NDSVI de cada etapa.

Como el rendimiento que se nos proporcionó corresponde solo al ciclo abril–octubre de 2025, las variables se calcularon únicamente con datos de ese año, ya que el rendimiento de una cosecha depende de las condiciones que tuvo el cultivo durante su propio ciclo.

Para el modelo de regresión se necesita un solo valor por parcela de cada una de las variables, dado que los datos están organizados de manera mensual. Por eso mismo, con los períodos de cada etapa fenológica se resumió cada variable del ciclo 2025. La lluvia se sumó para poder sacar la lluvia acumulada en la etapa, las temperaturas se les sacó el promedio, los indices de sentinel-2 se usó la mediana de la etapa y del EVI de planet se tomó su valor maximo, su mediana en el llenado de grano y el dia del año en que llegó a su verdor máximo. La elevacion y la pendeiente se usaron tal cual, ya que eso no cambuan con el tiempo.

Todas estas variables se unieron en una sola base con la funcion `left_join()` del paquete `dplyr`, identificandolas por parcela, las variables construidas se muestran en la tabla de abajo:

Modelo de regresión

Para predecir el rendimiento se usó una regresión lineal múltiple, ajustada solo con las 138 parcelas que tienen rendimiento (conjunto de entrenamiento); las 59 parcelas restantes se dejaron para la predicción final.

Antes de ajustar el modelo se revisó la correlación de Spearman entre las 14 variables construidas, usando la función `cor()` y un mapa de calor con el paquete `corrplot`. Cuando dos variables tenían una correlación mayor a 0.8, se conservó solo una para evitar problemas de multicolinealidad. Por esta razón, se quitaron tres variables de precipitación (`prec_crecimiento`, `prec_llenado` y `anomalia_prec`), y el modelo inicial quedó con 11 variables.

Con esas 11 variables se ajustó un primer modelo con la función `lm()`. Después, para quedarnos solo con las variables que realmente ayudan a explicar el rendimiento, se usó la selección paso a paso con la función `step()`, que quita o agrega variables una por una y se queda con el modelo de menor AIC.

Al modelo final se le revisaron los residuos con las gráficas de residuos contra valores ajustados y la gráfica Q-Q, para comprobar que se comportan como ruido.

Para saber qué tan bien predice el modelo las parcelas que no conoce, se hizo una validación cruzada de 5 grupos: las 138 parcelas a las que sí se les conoce su rendimiento se dividieron en 5 grupos al azar, usando la semilla `set.seed(123)` para que los grupos salieran exactamente iguales cada vez; se ajustó el modelo con 4 grupos y se predijo el que quedó fuera, repitiendo hasta predecir los 5 grupos. Con esas predicciones se calcularon el RMSE, el MAE y el R^2.

Ya como último, se predijo el rendimiento de las 59 parcelas del conjunto de predicción con la función `predict()`, y los resultados se guardaron en un archivo .csv.

Aplicación web

Para que los resultados del modelo se pudieran consultar de forma interactiva, se desarrollo una aplicación web en R con el paquete `shiny`, que permite crear paginas web intecractivas desde R, y el paquete `bslib`, que se usó para el diseño (las pestañas, los cuadros y los colores).

La aplicación lee las bases de datos construida para el modelo y al abrirla vuelve ajustar el modelo de regresión final con la función `lm()` y repite la validación cruzada de 5 grupos con la misma semilla, por lo que la aplicacion ejecuta el modelo y no solo muestra resultados guardados. La aplicación se organizó en seies pestañas:

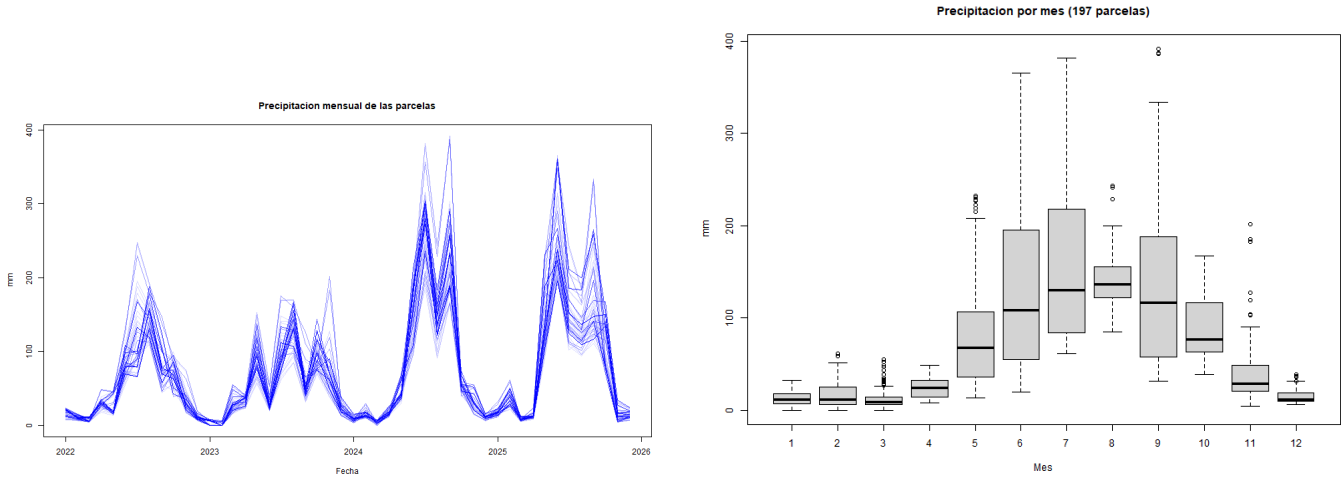
1. Cunsulta por parcelas
2. predicciones
3. simulador
4. información del modelo
5. pestaña con información del proyecto

Para publicarla se usó el paquete `shinylive`, que convierte la aplicación en una página web con la que cuenta R y se ejecuta directamente en el navegador, sin necesidad de un servidor. Los archivos se subieron a un repositorio de github y se publicaron con github pages. La aplicación puede consultarse en `https://calambres199.github.io/agrocebada/` y el código fuente en `https://github.com/Calambres199/agrocebada`.

Resultados

Precipitación

En la Figura 6 se muestran, del lado izquierdo, las series de precipitación mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. En la serie se logra observar que todas las parcelas siguen el mismo patrón, observamos que entre noviembre y marzo casi no llueve, las precipitaciones incrementan en abril y mayo y llega a sus valores mas altos en julio y agosto y vuelve a bajar en octubre, y ese patrón se repite cada año, es decir, la serie tiene estacionalidad. Tambien se observa que 2022 y 2023 fueron años mas secos que 2024 y 2025. El diagrama de caja confirma el patrón mencionado, entre julio y agosto están las mas altas y las mas bajas entre noviembre y marzo, además en los meses de lluvia se observa que las cajas son mas anchas, es decir, se observa mas diferencias de lluvia entre parcelas y entre años donde también aparecen valores atípicos.



(a) Series de las 197 parcelas, 2022–2025.

(b) Diagrama de caja por mes.

Figura 6: Precipitación mensual (mm) de las 197 parcelas.

Resultado	**Parcelas (de 197)**
Estacionaria según ADF ($p < 0{,}05$)	197
Estacionaria según KPSS ($p > 0{,}05$)	197
Estacionaria según Phillips-Perron ($p < 0{,}05$)	197
Estacionaria según las tres pruebas	197
Modelo con parte estacional [12]	197
Residuos como ruido (Ljung-Box $p > 0{,}05$)	197
Modelos elegidos	
`ARIMA(0,0,0)(0,1,1)[12]` con tendencia	159
`ARIMA(0,0,0)(1,1,0)[12]` con tendencia	38

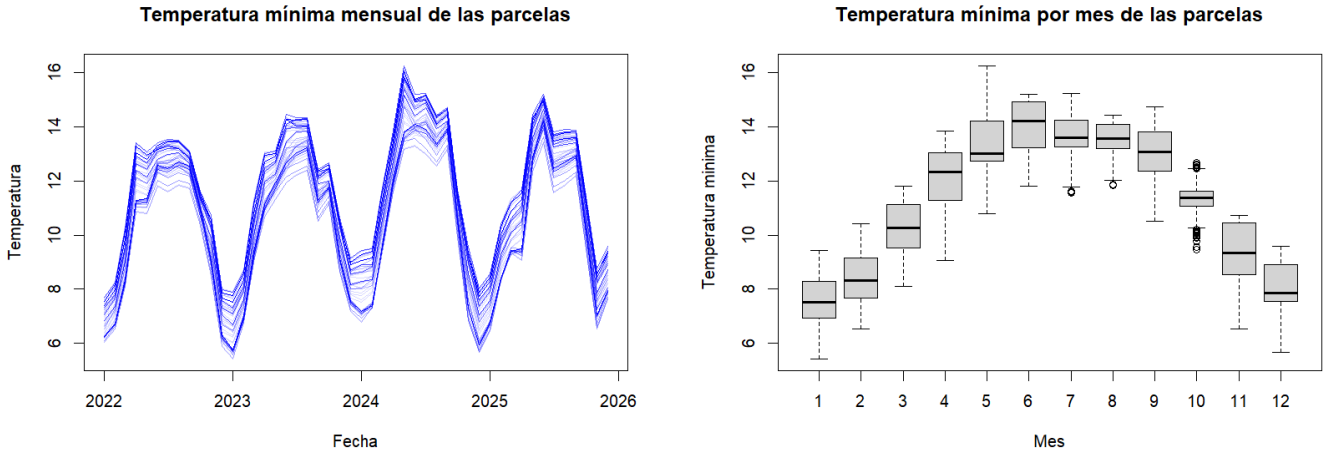
Cuadro 6: Resultados del análisis de series de tiempo de la precipitación.

En la Tabla 6 se observa que las tres pruebas coincidieron en que la serie de precipitación es estacionaria en las 197 parcelas. Sin embargo, todos los modelos elegidos incluyeron (*drift*), es decir, una constante que indica que, además del patrón que se repite cada año, la lluvia fue aumentando poco a poco de un año a otro.

En cuanto a los modelos, `auto.arima()` eligió solo dos modelos para todas las parcelas, y en ambos la parte no estacional es $(0, 0, 0)$: la lluvia de un mes no depende de la lluvia del mes anterior. En cambio, los dos modelos tienen parte estacional con una diferencia estacional ($D = 1$), lo que significa que la lluvia de un mes se relaciona con la lluvia del mismo mes del año anterior. Por último, en las 197 parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, por lo que los modelos capturaron la información de la serie.

Temperatura mínima

En la Figura 7 se muestran, del lado izquierdo, las series de temperatura mínima mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. En las series se observa que todas las parcelas siguen el mismo patrón cada año: las noches más frías ocurren en diciembre y enero, con temperaturas mínimas de alrededor de 7.5 °C, la temperatura sube a partir de marzo, llega a sus valores más altos en junio, con alrededor de 14 °C, se mantiene alta hasta septiembre y vuelve a bajar a partir de octubre. Es decir, la serie tiene estacionalidad. A diferencia de la precipitación, no se observa un año claramente distinto a los demás: la mediana anual de la temperatura mínima estuvo entre 11.2 y 11.8 °C en los cuatro años. El diagrama de caja confirma el patrón por mes: las medianas más altas están de junio a agosto y las más bajas en diciembre y enero.



(a) Series de las 197 parcelas, 2022–2025.

(b) Diagrama de caja por mes.

Figura 7: Temperatura mínima mensual (°C) de las 197 parcelas.

Resultado	Parcelas (de 197)
Estacionaria según ADF ($p < 0{,}05$)	197
Estacionaria según KPSS ($p > 0{,}05$)	197
Estacionaria según Phillips-Perron ($p < 0{,}05$)	0
Estacionaria según las tres pruebas	0
Modelo con parte estacional [12]	197
Residuos como ruido (Ljung-Box $p > 0{,}05$)	197
Modelos elegidos	
`ARIMA(0,1,1)(1,1,0)[12]`	147
`ARIMA(0,0,1)(1,1,0)[12]`	50

Cuadro 7: Resultados del análisis de series de tiempo de la temperatura mínima.

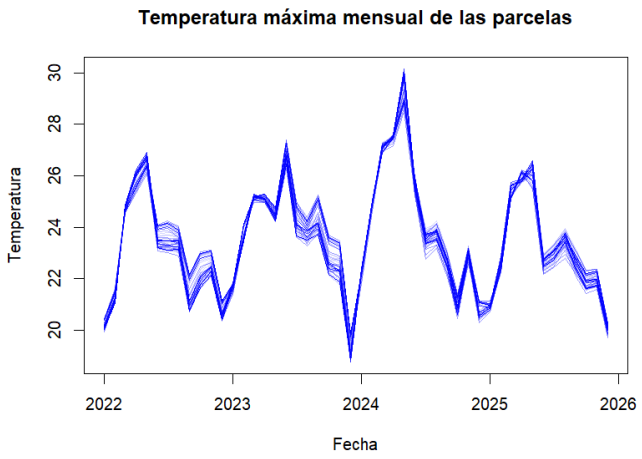
En la Tabla 7 se observa que, en este caso, las pruebas no coincidieron: la prueba ADF y la KPSS indicaron que la serie es estacionaria en las 197 parcelas, mientras que la de Phillips-Perron indicó que no lo es en ninguna. Por ello, ninguna parcela se consideró estacionaria según las tres pruebas.

En cuanto a los modelos, `auto.arima()` eligió dos modelos. En 147 parcelas eligió un modelo con una diferencia ($d = 1$), es decir, que trabaja con el cambio de temperatura de un mes a otro, lo que coincide con lo que indicó la prueba de Phillips-Perron. Los dos modelos tienen en la parte no estacional un término de medias móviles ($q = 1$), lo que significa que la temperatura de un mes se relaciona con el error del mes anterior: si un mes fue más frío o más caliente de lo esperado, eso influye un poco en el mes siguiente. Además, los dos tienen parte estacional con una diferencia estacional ($D = 1$) y un término autorregresivo estacional ($P = 1$), lo que significa que la temperatura de un mes se relaciona con la del mismo mes del año anterior. Por último, en las 197 parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, por lo que los modelos capturaron la información de la serie.

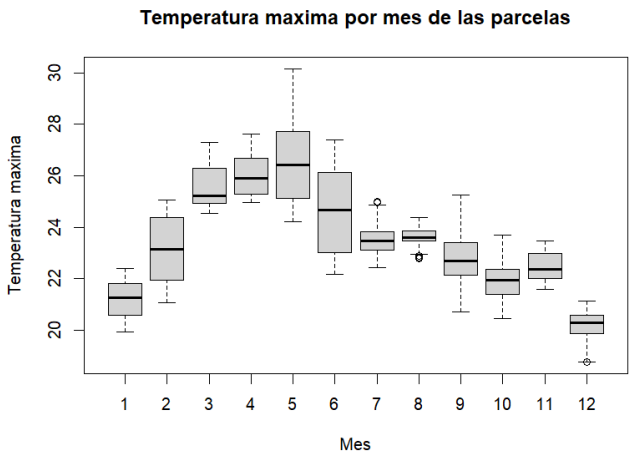
Temperatura máxima

En la Figura 8 se muestran, del lado izquierdo, las series de temperatura máxima mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. En las series se observa que las líneas de las 197 parcelas van casi encimadas, es decir, todas las parcelas tuvieron una temperatura máxima muy parecida, y las diferencias se dan más entre años que entre parcelas. Cada año se repite el mismo patrón: la temperatura máxima sube de enero a mayo, cuando alcanza sus valores más altos, baja a partir de junio y llega a sus valores más bajos en diciembre; es decir, la serie tiene estacionalidad. El año más caluroso fue 2024, con casi 30 °C en mayo, mientras que en 2023 el valor más alto no se presentó en mayo sino en junio, y diciembre de 2023 fue el mes más frío del periodo, con cerca de 19 °C.

El diagrama de caja confirma este patrón: las medianas más altas se encuentran de marzo a mayo, con alrededor de 26 °C en mayo, y la más baja en diciembre, con alrededor de 20 °C. La caja de junio es la más ancha, es decir, es el mes en que la temperatura máxima cambió más de un año a otro, mientras que las de julio y agosto son las más angostas, lo que indica que en esos meses la temperatura fue muy parecida todos los años. También se observan algunos valores atípicos en julio, agosto y diciembre.



(a) Series de las 197 parcelas, 2022–2025.



(b) Diagrama de caja por mes.

Figura 8: Temperatura máxima mensual (°C) de las 197 parcelas.

Resultado	**Parcelas (de 197)**
Estacionaria según ADF ($p < 0{,}05$)	197
Estacionaria según KPSS ($p > 0{,}05$)	197
Estacionaria según Phillips-Perron ($p < 0{,}05$)	197
Estacionaria según las tres pruebas	197
Modelo con parte estacional [12]	197
Residuos como ruido (Ljung-Box $p > 0{,}05$)	197
Modelo elegido	
`ARIMA(0,1,1)(1,1,0)[12]`	197

Cuadro 8: Resultados del análisis de series de tiempo de la temperatura máxima.

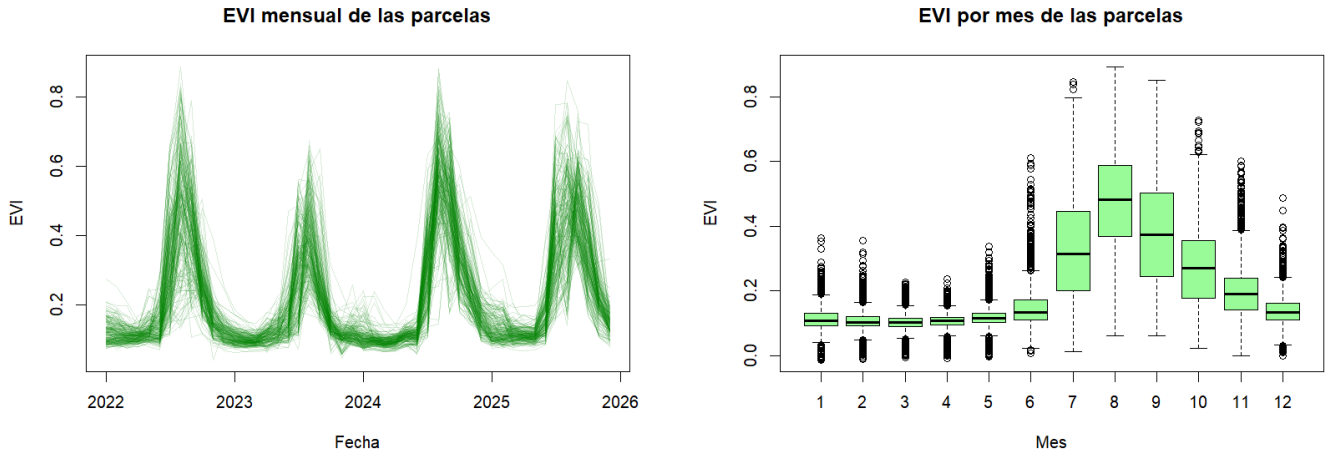
En la Tabla 8 se observa que las tres pruebas coincidieron en que la serie de temperatura máxima es estacionaria en las 197 parcelas, y que `auto.arima()` eligió el mismo modelo para todas: `ARIMA(0,1,1)(1,1,0)[12]`, que es también el modelo que se eligió en la mayoría de las parcelas para la temperatura mínima.

Este modelo tiene una diferencia estacional ($D = 1$) y un término autorregresivo estacional ($P = 1$), lo que significa que la temperatura máxima de un mes se relaciona con la del mismo mes del año anterior. Además, tiene una diferencia en la parte no estacional ($d = 1$) y un término de medias móviles ($q = 1$): después de comparar cada mes con el del año anterior, el modelo trabaja con el cambio de un mes a otro, y la temperatura de un mes se relaciona con el error del mes anterior. Por último, en las 197 parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, por lo que los modelos capturaron la información de la serie.

EVI

En la Figura 9 se muestran, del lado izquierdo, las series del EVI mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. En las series se observa que el EVI tiene el ciclo más marcado de todas las variables: de enero a mayo se mantiene bajo, alrededor de 0.1, ya que todavía no hay cultivo o la planta es muy pequeña; a partir de junio sube rápidamente, llega a sus valores más altos en agosto y después baja poco a poco hasta diciembre, cuando el cultivo madura y se cosecha. Este patrón se repite cada año, es decir, la serie tiene estacionalidad. Sin embargo, no todos los años alcanzaron el mismo verdor: en 2023 el valor más alto fue menor que en 2022, 2024 y 2025. Además, a diferencia de la temperatura, en los meses de mayor verdor las líneas se separan mucho entre sí: algunas parcelas llegaron a un EVI de 0.3 y otras a más de 0.8, es decir, hubo parcelas mucho más verdes que otras.

El diagrama de caja confirma este patrón: de enero a mayo las cajas son muy angostas y cercanas a 0.1, la mediana sube a partir de junio, llega a su valor más alto en agosto, con alrededor de 0.48, y baja de septiembre a diciembre. Las cajas de julio a octubre son las más anchas, lo que coincide con la gran diferencia de verdor entre parcelas en esos meses. También se observan muchos valores atípicos, sobre todo de enero a junio y en octubre y noviembre; por esta razón, como se mencionó en la metodología, cuando un mes tenía varias imágenes se usó la mediana y no el promedio.



(a) Series de las 197 parcelas, 2022–2025.

(b) Diagrama de caja por mes.

Figura 9: EVI mensual de las 197 parcelas (Sentinel-2).

Resultado	Parcelas (de 197)	Porcentaje
Estacionaria según ADF ($p < 0{,}05$)	190	96.4 %
Estacionaria según KPSS ($p > 0{,}05$)	195	99.0 %
Estacionaria según Phillips-Perron ($p < 0{,}05$)	63	32.0 %
Estacionaria según las tres pruebas	61	31.0 %
Modelo con parte estacional [12]	195	99.0 %
Modelo con deriva (*drift*)	27	13.7 %
Residuos como ruido (Ljung-Box $p > 0{,}05$)	194	98.5 %
Modelos más comunes		
`ARIMA(0,0,1)(1,1,0)[12]`	32	16.2 %
`ARIMA(1,0,0)(1,1,0)[12]`	28	14.2 %
`ARIMA(0,0,0)(0,1,0)[12]`	16	8.1 %
Otros (35 modelos distintos)	121	61.4 %

Cuadro 9: Resultados del análisis de series de tiempo del EVI.

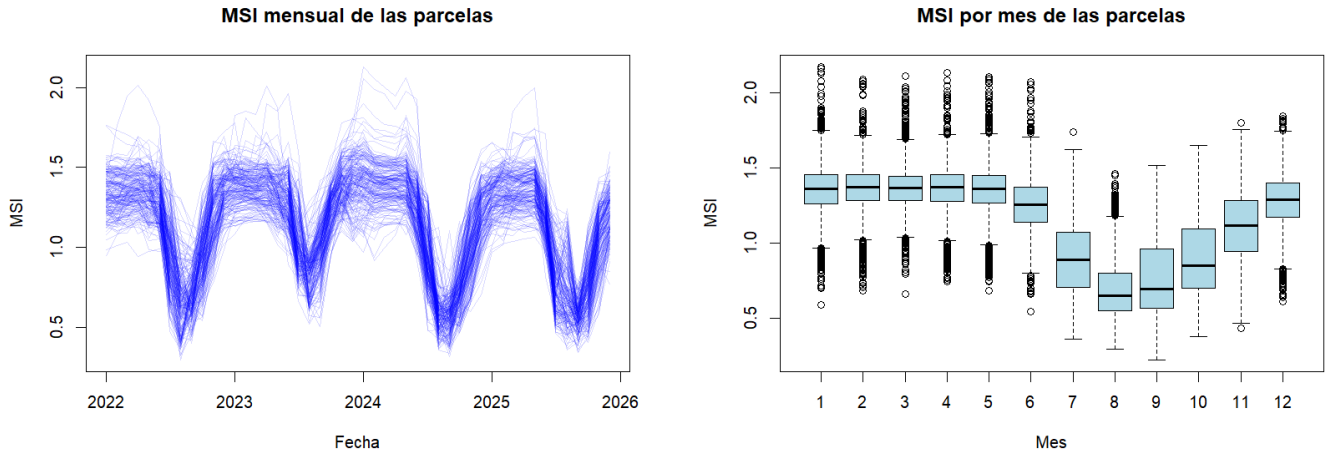
En la Tabla 9 se observa que, igual que en la temperatura mínima, las pruebas no coincidieron: la ADF y la KPSS indicaron que la serie es estacionaria en casi todas las parcelas, mientras que la de Phillips-Perron solo lo indicó en el 32 %. Por ello, solo el 31 % de las parcelas se consideró estacionaria según las tres pruebas.

A diferencia de las variables de clima, en el EVI `auto.arima()` no eligió uno o dos modelos para todas las parcelas, sino 38 modelos distintos; el más común, `ARIMA(0,0,1)(1,1,0)[12]`, solo se eligió en el 16 % de las parcelas. Esto indica que cada parcela tiene un comportamiento del verdor un poco distinto. Sin embargo, en casi todas (99 %) el modelo tuvo parte estacional con una diferencia estacional ($D = 1$), es decir, el EVI de un mes se relaciona con el del mismo mes del año anterior. En la parte no estacional, la mayoría de los modelos no tuvo diferencia ($d = 0$) y tuvo un término autorregresivo o de medias móviles, lo que indica que el EVI de un mes también se relaciona con el del mes anterior, algo que tiene sentido porque la planta crece poco a poco. Solo el 14 % de los modelos consideró derivar la serie buscando estacionalidad. Por último, en el 98.5 % de las parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, y la media de los residuos fue prácticamente cero en todas, por lo que los modelos capturaron la información de la serie.

MSI

En la Figura 10 se muestran, del lado izquierdo, las series del MSI mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. Hay que recordar que en el MSI un valor más bajo indica que la planta tiene más agua, y un valor más alto, que está más seca. En las series se observa que el MSI tiene un comportamiento contrario al del EVI: de enero a mayo se mantiene alto, alrededor de 1.35, ya que es la temporada seca y todavía no hay cultivo; a partir de junio baja rápidamente, llega a sus valores más bajos en agosto y septiembre, cuando el cultivo está más verde y tiene más agua, y vuelve a subir de octubre a diciembre, cuando la planta madura y se seca. Este patrón se repite cada año, es decir, la serie tiene estacionalidad. Sin embargo, no todos los años fueron iguales: en 2023 el MSI no bajó tanto como en los otros años, es decir, las plantas tuvieron menos agua, lo que coincide con que ese año el EVI también alcanzó valores más bajos.

El diagrama de caja confirma este patrón: de enero a mayo las medianas se mantienen alrededor de 1.36 con cajas angostas, la mediana baja a partir de junio y llega a su valor más bajo en agosto, con alrededor de 0.65, y vuelve a subir de octubre a diciembre. Las cajas de julio a octubre son las más anchas, es decir, en esos meses hubo más diferencia en el agua de la planta entre parcelas y entre años. También se observan muchos valores atípicos, sobre todo de enero a junio y en agosto.



(a) Series de las 197 parcelas, 2022–2025.

(b) Diagrama de caja por mes.

Figura 10: MSI mensual de las 197 parcelas (Sentinel-2).

Resultado	**Parcelas (de 197)**	**Porcentaje**
Estacionaria según ADF ($p < 0{,}05$)	167	84.8 %
Estacionaria según KPSS ($p > 0{,}05$)	197	100 %
Estacionaria según Phillips-Perron ($p < 0{,}05$)	2	1.0 %
Estacionaria según las tres pruebas	2	1.0 %
Modelo con parte estacional [12]	197	100 %
Modelo con deriva (*drift*)	15	7.6 %
Residuos como ruido (Ljung-Box $p > 0{,}05$)	192	97.5 %
Modelos más comunes		
`ARIMA(1,0,0)(1,1,0)[12]`	70	35.5 %
`ARIMA(1,0,0)(0,1,1)[12]`	23	11.7 %
`ARIMA(0,1,0)(1,1,0)[12]`	12	6.1 %
Otros (24 modelos distintos)	92	46.7 %

Cuadro 10: Resultados del análisis de series de tiempo del MSI.

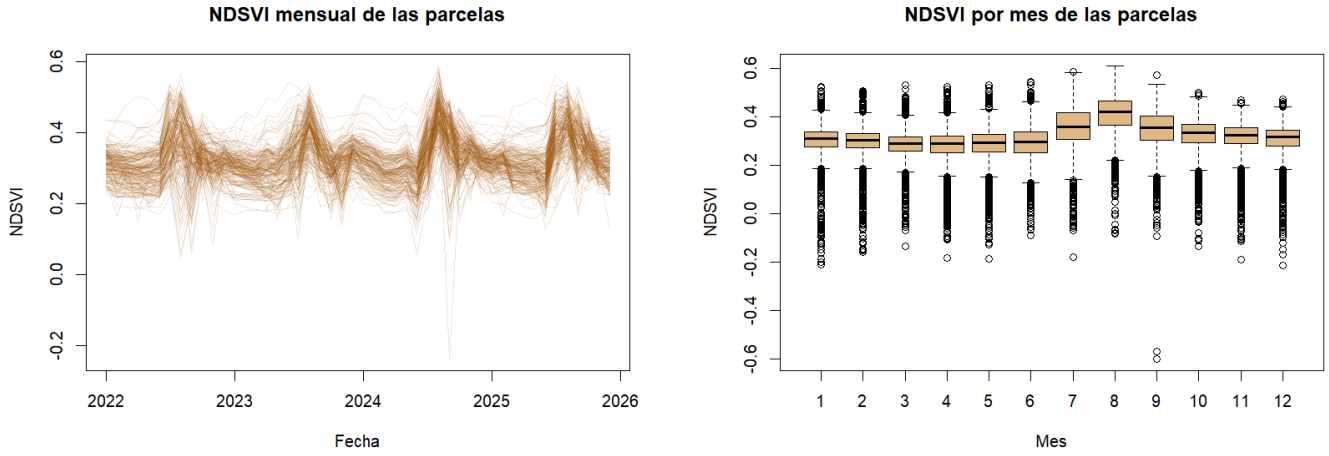
En la Tabla 10 se observa que, igual que en la temperatura mínima y el EVI, las pruebas no coincidieron: la KPSS indicó que la serie es estacionaria en todas las parcelas y la ADF en el 84.8 %, mientras que la de Phillips-Perron solo lo indicó en 2 parcelas. Por ello, solo el 1 % de las parcelas se consideró estacionaria según las tres pruebas.

En cuanto a los modelos, `auto.arima()` eligió 27 modelos distintos, aunque, a diferencia del EVI, hubo uno claramente más común: `ARIMA(1,0,0)(1,1,0)[12]`, en el 35.5 % de las parcelas. Este modelo tiene en la parte no estacional un término autorregresivo ($p = 1$), es decir, el MSI de un mes se relaciona con el del mes anterior, y en la parte estacional una diferencia estacional ($D = 1$) y un término autorregresivo estacional ($P = 1$), es decir, el MSI de un mes se relaciona con el del mismo mes del año anterior. En todas las parcelas el modelo tuvo parte estacional con diferencia estacional, y solo el 7.6 % consideró derivar la serie para buscar estacionalidad. Por último, en el 97.5 % de las parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, y la media de los residuos fue prácticamente cero, por lo que los modelos capturaron la información de la serie.

NDSVI

En la Figura 11 se muestran, del lado izquierdo, las series del NDSVI mensual de las 197 parcelas de enero de 2022 a diciembre de 2025 y, del lado derecho, el diagrama de caja por mes. A diferencia del EVI y del MSI, el NDSVI cambia poco a lo largo del año: la mayor parte del tiempo se mantiene alrededor de 0.3, y solo sube en julio y agosto, cuando llega a valores de entre 0.4 y 0.5, para después volver a bajar. Este aumento se repite cada año, pero es mucho menos marcado que en los otros índices. En las series también se observan bajadas bruscas en algunas parcelas, que llegan incluso a valores negativos.

El diagrama de caja confirma este comportamiento: de enero a junio las medianas se mantienen alrededor de 0.3, suben en julio y llegan a su valor más alto en agosto, con alrededor de 0.42, y de septiembre a diciembre regresan a valores cercanos a 0.3. Las cajas son angostas en todos los meses, pero hay una gran cantidad de valores atípicos, sobre todo hacia abajo, con valores de hasta $-0{,}2$ y algunos casos de $-0{,}6$ en septiembre; estos valores pueden deberse a nubes o sombras que no se eliminaron con el filtro de nubosidad, y por ello también se usó la mediana cuando un mes tenía varias imágenes.



(a) Series de las 197 parcelas, 2022–2025.

(b) Diagrama de caja por mes.

Figura 11: NDSVI mensual de las 197 parcelas (Sentinel-2).

Resultado	Parcelas (de 197)	Porcentaje
Estacionaria según ADF ($p < 0{,}05$)	166	84.3 %
Estacionaria según KPSS ($p > 0{,}05$)	187	94.9 %
Estacionaria según Phillips-Perron ($p < 0{,}05$)	187	94.9 %
Estacionaria según las tres pruebas	150	76.1 %
Modelo con parte estacional [12]	157	79.7 %
Modelo con deriva (*drift*)	12	6.1 %
Residuos como ruido (Ljung-Box $p > 0{,}05$)	190	96.4 %
Modelos más comunes		
`ARIMA(0,0,0)(0,1,0)[12]`	23	11.7 %
`ARIMA(0,0,0)(1,1,0)[12]`	18	9.1 %
`ARIMA(0,0,0)(1,0,0)[12]` con media	14	7.1 %
`ARIMA(0,0,1)(1,1,0)[12]`	14	7.1 %
`ARIMA(1,0,0)(1,1,0)[12]`	14	7.1 %
Otros (35 modelos distintos)	114	57.9 %

Cuadro 11: Resultados del análisis de series de tiempo del NDSVI.

En la Tabla 11 se observa que, a diferencia de los otros índices, en el NDSVI las tres pruebas sí coincidieron en la mayoría de las parcelas: el 76.1 % se consideró estacionaria según las tres pruebas. Esto coincide con lo que se observa en las gráficas: el NDSVI se mantiene casi todo el año alrededor del mismo valor.

En cuanto a los modelos, `auto.arima()` eligió 40 modelos distintos, y ninguno se eligió en más del 12 % de las parcelas. El 79.7 % de los modelos tuvo parte estacional, es decir, el NDSVI de un mes se relaciona con el del mismo mes del año anterior; sin embargo, este porcentaje es menor que en el resto de las variables, y en el 20.3 % de las parcelas el modelo no tuvo parte estacional. Varios de los modelos elegidos aparecen como *with non-zero mean*, lo que indica que la serie se mantiene alrededor de un valor promedio distinto de cero, lo que coincide con que la serie sea estacionaria. Solo el 6.1 % de los modelos consideró necesario derivar la serie. Por último, en el 96.4 % de las parcelas la prueba de Ljung-Box indicó que los residuos se comportan como ruido, y la media de los residuos fue prácticamente cero, por lo que los modelos capturaron la información de la serie.

Modelo de regresión

Relación de las variables con el rendimiento

Antes de ajustar el modelo, se calculó la correlación de Spearman entre cada variable y el rendimiento de las 138 parcelas de entrenamiento (Tabla 12). Las variables más relacionadas con el rendimiento fueron las de clima: la lluvia en la siembra tuvo la correlación más fuerte ($-0{,}66$), es decir, las parcelas donde llovió más de abril a junio tuvieron menor rendimiento, seguida de la temperatura mínima del ciclo (0,54), es decir, las parcelas con noches menos frías rindieron más. En cambio, los índices satelitales tuvieron correlaciones débiles, todas menores a 0.3 en valor absoluto.

Variable	Correlación con el rendimiento
prec_siembra	−0,66
tmin_ciclo	0.54
anomalia_prec	−0,51
prec_llenado	−0,42
tmax_llenado	−0,38
prec_crecimiento	−0,30
ndsvi_madurez	0.28
elevacion_m	0.25
AREA_HA	−0,25
evi_llenado_planet	−0,25
pendiente_grados	0.23
evi_max_planet	−0,21
msi_llenado	0.17
dia_pico_planet	0.10

Cuadro 12: Correlación de Spearman entre cada variable y el rendimiento (138 parcelas de entrenamiento).

En la Figura 12 se muestran las gráficas de dispersión de las cuatro variables más relacionadas con el rendimiento. En las tres variables de lluvia se observan dos grupos de parcelas: las que tuvieron menos lluvia, con rendimientos de entre 4 y 5.5 t/ha, y las que tuvieron más lluvia, con rendimientos de entre 2 y 3.5 t/ha. Algo parecido ocurre con la temperatura mínima: las parcelas con temperatura mínima menor a 12.8 °C tuvieron rendimientos de 3.5 t/ha o menos, mientras que la mayoría de las parcelas con más de 13 °C rindieron entre 4 y 5.5 t/ha. También se observa que los puntos forman columnas, es decir, muchas parcelas tienen exactamente el mismo valor de lluvia o de temperatura, y que el rendimiento aparece en valores redondeados (2.5, 3.0, 3.5 t/ha).

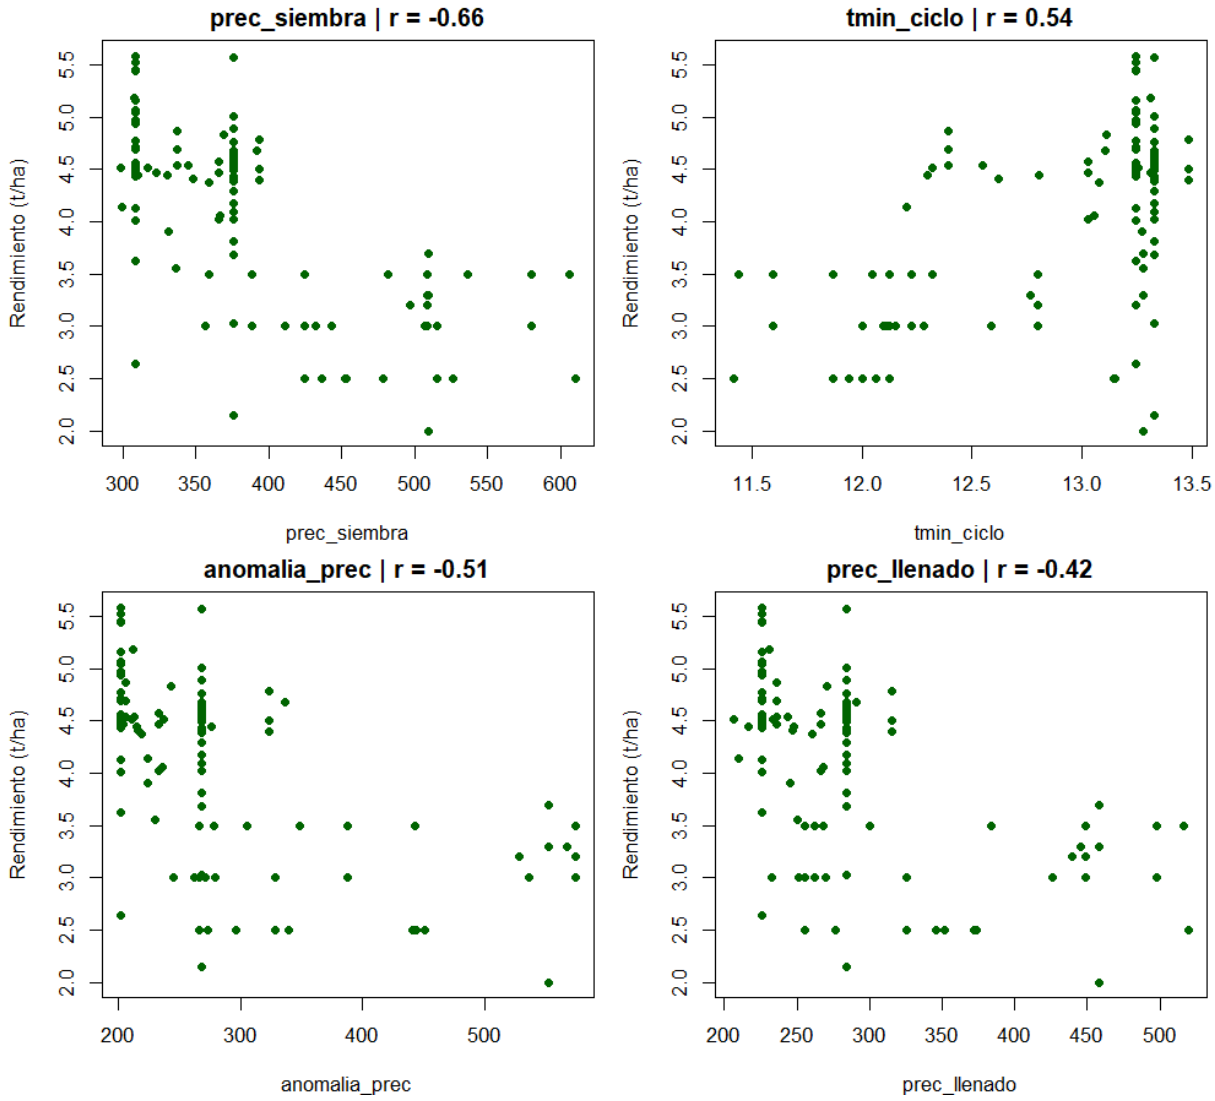


Figura 12: Rendimiento contra las cuatro variables más relacionadas (138 parcelas de entrenamiento).

Correlación entre variables

En la Figura 13 se muestra la correlación de Spearman entre las 14 variables construidas. Las correlaciones más altas se presentaron entre las variables de precipitación: `prec_llenado` y `anomalia_prec` (0.95), `prec_crecimiento` y `prec_llenado` (0.94), `prec_siembra` y `anomalia_prec` (0.88), `prec_siembra` y `prec_llenado` (0.87) y `prec_crecimiento` y `anomalia_prec` (0.87). Es decir, las parcelas donde llovió más en una etapa también fueron las que más lluvia tuvieron en las otras. Como estas correlaciones son mayores a 0.8, se conservó solo `prec_siembra`, que fue la más relacionada con el rendimiento, y se quitaron las otras tres.

También se observaron correlaciones moderadas, menores a 0.8, por lo que estas variables se conservaron: `msi_llenado` y `evi_llenado_planet` ($-0{,}74$), es decir, las parcelas más verdes tuvieron más agua; `tmax_llenado` y `elevacion_m` ($-0{,}73$), es decir, las parcelas más altas tuvieron menos calor; `evi_max_planet` y `evi_llenado_planet` (0.69), y `elevacion_m` y `pendiente_grados` (0.63), es decir, las parcelas más altas son también las más inclinadas.

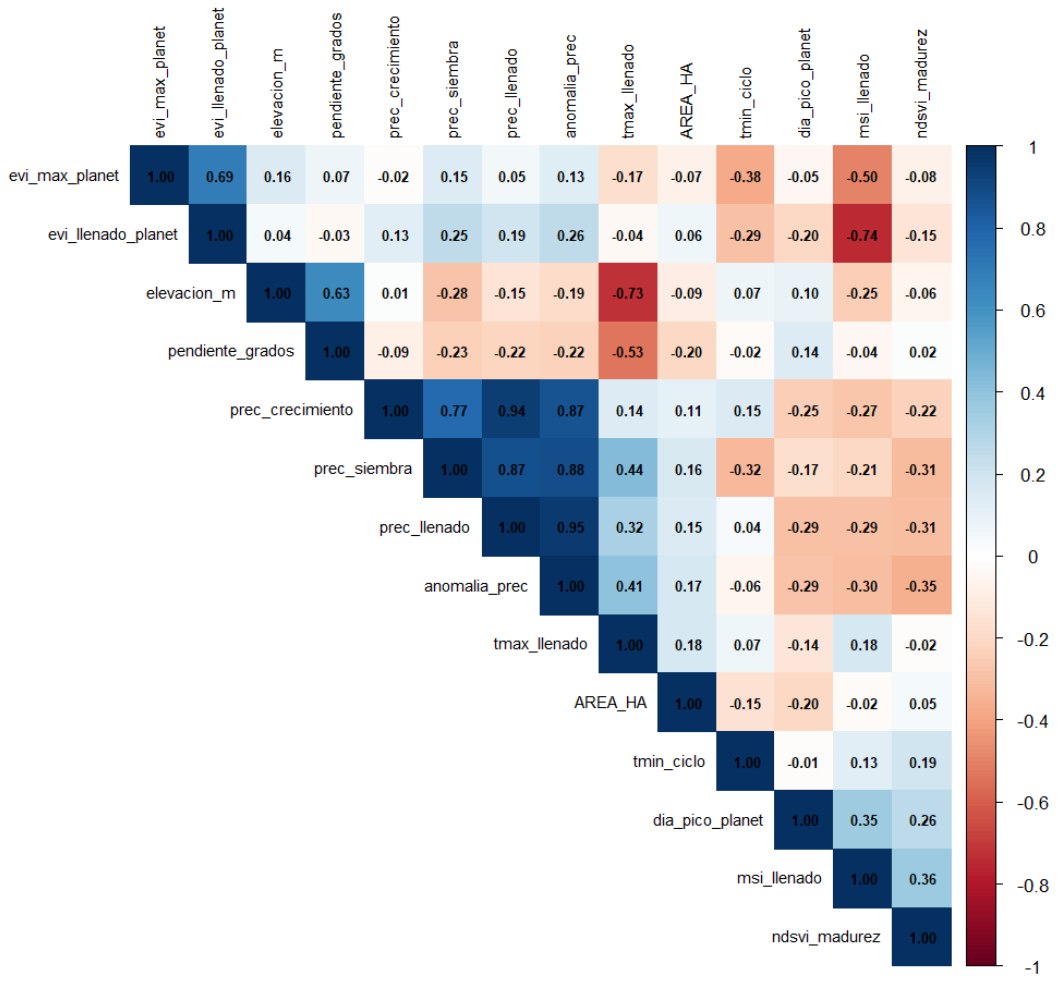


Figura 13: Correlación de Spearman entre las variables construidas (138 parcelas de entrenamiento).

Selección de variables

El modelo inicial con las 11 variables tuvo un R^2 de 0.621 y un R^2 ajustado de 0.588, pero solo tres variables fueron significativas ($p < 0{,}05$): `prec_siembra`, `tmin_ciclo` y `tmax_llenado`. Con la selección paso a paso, la función `step()` fue quitando una por una las variables que no mejoraban el modelo, como se muestra en la Tabla 13. En cada paso el AIC disminuyó, hasta llegar a un modelo con cinco variables, en el que quitar o agregar cualquier otra variable ya no disminuía el AIC.

Paso	Variable que se quitó	Variables en el modelo	AIC del modelo
0	Ninguna (modelo inicial)	11	−155,35
1	`evi_llenado_planet`	10	−157,34
2	`AREA_HA`	9	−159,33
3	`msi_llenado`	8	−161,22
4	`evi_max_planet`	7	−162,86
5	`dia_pico_planet`	6	−164,33
6	`ndsvi_madurez`	5	−165,91

Cuadro 13: Variables eliminadas en la selección paso a paso con `step()`.

Como se observa, todos los índices satelitales se eliminaron del modelo, al igual que el área de la parcela. El modelo final quedó con tres variables de clima (`prec_siembra`, `tmin_ciclo` y `tmax_llenado`) y dos de topografía (`elevacion_m` y `pendiente_grados`). Al quitar seis variables, el R^2 casi no cambió (de 0.621 a 0.617), mientras que el R^2 ajustado aumentó de 0.588 a 0.602.

Modelo final

En la Tabla 14 se muestran los coeficientes del modelo final.

Variable	Coeficiente	Error estándar	p-valor
Intercepto	28.3781	8.3781	$< 0{,}001$
`prec_siembra`	−0,0046	0.0007	$< 0{,}001$
`tmin_ciclo`	0.6470	0.1093	$< 0{,}001$
`tmax_llenado`	−1,1864	0.3228	$< 0{,}001$
`elevacion_m`	−0,0014	0.0007	0.064
`pendiente_grados`	0.0533	0.0268	0.049
$R^2 = 0{,}617$	R^2 ajustado $= 0{,}602$	Error estándar residual $= 0{,}537$ t/ha	

Cuadro 14: Coeficientes del modelo de regresión final.

La ecuación del modelo queda de la siguiente forma:

$$\widehat{\text{Rendimiento}} = 28{,}378 - 0{,}0046\,\text{prec_siembra} + 0{,}647\,\text{tmin_ciclo} - 1{,}186\,\text{tmax_llenado} - 0{,}0014\,\text{elevacion_m} + 0{,}053\,\text{pendiente_grados}$$

Los coeficientes se interpretan así, manteniendo constantes las demás variables:

- **Lluvia en la siembra:** por cada 100 mm más de lluvia de abril a junio, el rendimiento disminuye en promedio 0.46 t/ha.
- **Temperatura mínima del ciclo:** por cada grado más de temperatura mínima, el rendimiento aumenta en promedio 0.65 t/ha; es decir, las parcelas con noches menos frías rindieron más.

- **Temperatura máxima en el llenado:** por cada grado más de temperatura máxima en agosto y septiembre, el rendimiento disminuye en promedio 1.19 t/ha; es decir, el calor en el llenado del grano afecta el rendimiento.
- **Elevación:** por cada 100 m más de altura, el rendimiento disminuye en promedio 0.14 t/ha.
- **Pendiente:** por cada grado más de inclinación, el rendimiento aumenta en promedio 0.05 t/ha.

Las tres variables de clima fueron significativas ($p < 0{,}001$) y la pendiente también ($p = 0{,}049$). La elevación tuvo un p-valor de 0.064, ligeramente mayor que 0.05, por lo que no es significativa al 5 %; sin embargo, `step()` la conservó porque su inclusión disminuye el AIC. El modelo en conjunto es significativo ($F = 42{,}52$, $p < 0{,}001$) y explica el 61.7 % de la variabilidad del rendimiento de las 138 parcelas.

Diagnóstico de residuos

En la Figura 14 se muestran las gráficas de diagnóstico de los residuos del modelo final. En la gráfica de residuos contra valores ajustados, los puntos se distribuyen alrededor de cero, la línea roja es casi plana y no se forma un embudo, por lo que no hay una tendencia que el modelo no haya capturado y la varianza es aproximadamente constante; además, la media de los residuos fue prácticamente cero. En esta gráfica también se distinguen dos grupos de puntos, uno con valores ajustados de entre 3 y 3.6 t/ha y otro de entre 4 y 5 t/ha, que corresponden a los dos grupos de parcelas observados en las gráficas de dispersión. En la gráfica Q-Q, los residuos siguen la línea diagonal en casi todo su recorrido, por lo que su distribución es aproximadamente normal; solo se separan en la parte inferior izquierda, debido a unas pocas parcelas con residuos muy negativos.

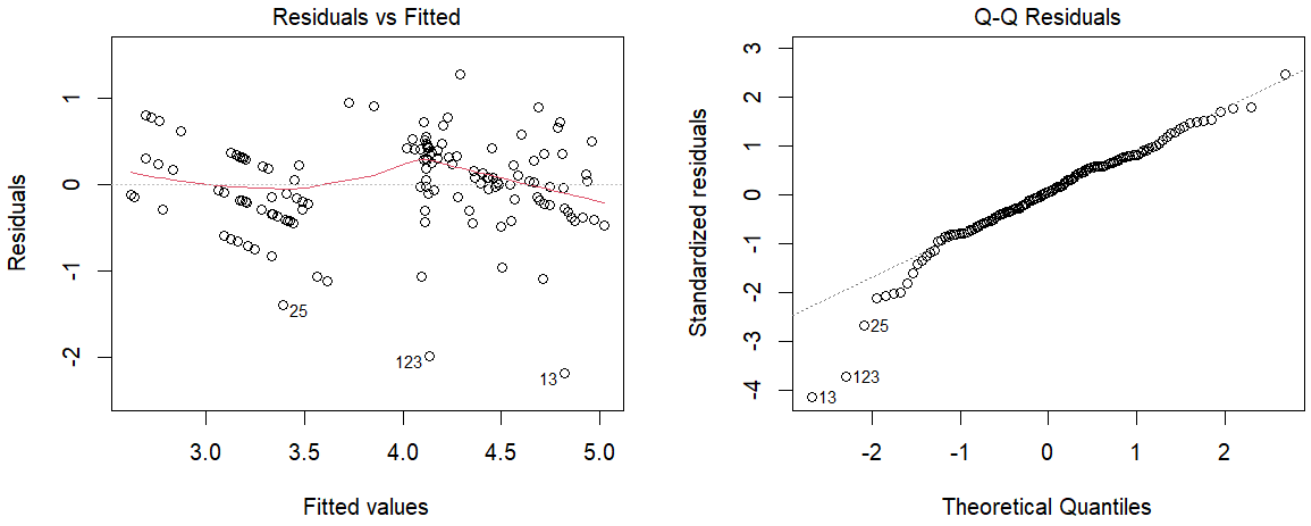


Figura 14: Residuos contra valores ajustados (izquierda) y gráfica Q-Q de los residuos (derecha) del modelo final.

Las parcelas marcadas en las gráficas son las que tuvieron los residuos más grandes (Tabla 15). Las tres tuvieron un rendimiento real muy bajo, y el modelo les asignó un rendimiento mucho mayor, es decir, las sobreestimó.

Parcela	Municipio	Real (t/ha)	Ajustado (t/ha)	Residuo
AGC_015	Chignahuapan	2.64	4.82	−2,18
AGC_171	Chignahuapan	2.15	4.13	−1,98
AGC_034	Singuilucan	2.00	3.39	−1,39

Cuadro 15: Parcelas con los residuos más grandes del modelo final.

Validación cruzada

Con la validación cruzada de 5 grupos se obtuvieron un RMSE de 0.560 t/ha, un MAE de 0.420 t/ha y un R^2 de 0.565. Es decir, al predecir parcelas que el modelo no conocía, se equivocó en promedio 0.42 t/ha y explicó el 56.5 % de la variabilidad del rendimiento. Este R^2 es un poco menor que el del modelo ajustado con todas las parcelas (0.617), y el RMSE es muy parecido al error estándar residual del modelo (0.537 t/ha), lo que indica que el modelo no está sobreajustado: predice parcelas nuevas casi igual de bien que las que usó para ajustarse.

En la Figura 15 se muestra el rendimiento real contra el predicho en la validación cruzada. Se observan los mismos dos grupos: las parcelas con rendimiento real de entre 2.5 y 3.5 t/ha recibieron predicciones de entre 2.6 y 3.7 t/ha, y las de entre 4 y 5.6 t/ha, de entre 3.7 y 5 t/ha. Sin embargo, dentro de cada grupo los puntos se alejan de la línea: por ejemplo, las parcelas con un rendimiento real de 3 t/ha recibieron predicciones de entre 2.6 y 4 t/ha. Además, el modelo tiende a subestimar las parcelas con los rendimientos más altos, cercanos a 5.5 t/ha, y a sobreestimar las de rendimientos más bajos.

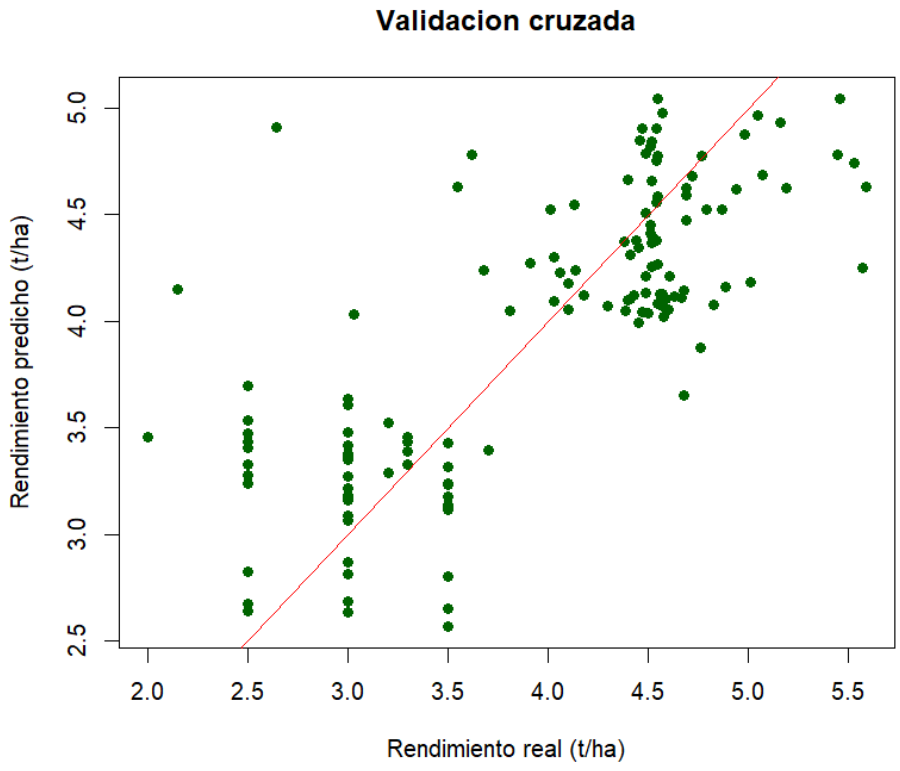


Figura 15: Rendimiento real contra rendimiento predicho en la validación cruzada. La línea roja marca donde el valor real es igual al predicho.

Predicción de las 59 parcelas

Con el modelo final se predijo el rendimiento de las 59 parcelas del conjunto de predicción. El rendimiento predicho fue de entre 2.63 y 5.02 t/ha, con una mediana de 4.12 t/ha y un promedio de 3.90 t/ha, muy parecido al promedio real de las 138 parcelas de entrenamiento (3.96 t/ha). En la Tabla 16 se muestra el rendimiento predicho por municipio, junto con el rendimiento real de las parcelas de entrenamiento del mismo municipio.

Municipio	Parcelas a predecir	Predicho promedio	Parcelas con rendimiento	Real promedio
Chignahuapan	29	4.38	71	4.48
Cuautepec de Hinojosa	4	4.36	5	4.60
Almoloya	4	4.15	10	4.52
Singuilucan	7	3.47	16	3.08
Nanacamilpa de Mariano Arista	1	3.30	1	2.50
Calpulalpan	14	2.97	30	3.00

Cuadro 16: Rendimiento predicho (t/ha) de las 59 parcelas por municipio, comparado con el rendimiento real de las parcelas de entrenamiento.

Se observa que las predicciones conservan el mismo patrón que los rendimientos reales: Chignahuapan, Cuautepec de Hinojosa y Almoloya tienen los rendimientos más altos, mientras que Calpulalpan y Singuilucan tienen los más bajos.

Antecedentes

La estimación del rendimiento de la cebada en México se ha abordado desde hace varios años. Ruiz-Huanca et al. [8] estimaron el rendimiento de cebada en el Distrito de Riego 011, en Guanajuato, con imágenes Landsat y MODIS. Encontraron que el EVI, medido alrededor de 80 días después de la siembra, predijo el rendimiento con un r^2 de 0.93, aunque señalaron que la resolución de MODIS (250 a 1000 m) es demasiado gruesa para parcelas pequeñas.

Más tarde, Gómez Mercado et al. [1] estimaron el rendimiento de cebada maltera en Almoloya, Apan y Villa de Tezontepec, en Hidalgo, durante el ciclo primavera-verano de 2006, usando el método agroclimático de la FAO con datos de estaciones meteorológicas y mediciones en campo. Obtuvieron un error promedio de alrededor del 10 %, aceptable a nivel regional; sin embargo, el método no logró captar las diferencias entre localidades ni entre variedades.

En España, Barallat Pérez [6] analizó parcelas de trigo y cebada de temporal en Ávila y Segovia durante cuatro campañas (2015 a 2019), con series de tiempo del NDVI obtenidas de imágenes Landsat-8 y Sentinel-2 y datos de temperatura y precipitación. El NDVI acumulado explicó el rendimiento con un R^2 de entre 0.84 y 0.93, y la precipitación tuvo una correlación de alrededor de 0.8 con el rendimiento; las campañas con menor rendimiento fueron las que tuvieron más calor y menos agua. Además, con el NDVI construyó un índice de alarma para apoyar la decisión de ampliar la cobertura del seguro agrícola.

Más recientemente, Iranzo et al. [7] estimaron la producción de cebada en una explotación de 127 ha en Belchite, España, con datos de cinco temporadas. Con series de tiempo de índices de vegetación de Sentinel-2, del índice de radar de Sentinel-1 y de variables climáticas definieron el calendario agronómico del cultivo, y con base en él construyeron variables por etapa: la precipitación se sumó, la temperatura se promedió y de los índices se tomaron el promedio, el máximo y el mínimo de cada etapa. Con estas variables ajustaron modelos de regresión lineal múltiple, validados con validación cruzada, que explicaron entre el 78 % y el 98 % de la variabilidad de la producción; el mejor modelo incluyó la temperatura máxima de la etapa de desarrollo del cultivo.

Estos trabajos muestran que el clima y los índices satelitales pueden ayudar a estimar el rendimiento de la cebada, y que es útil construir las variables según las etapas del cultivo. Sin embargo, la mayoría compara el rendimiento entre distintos años en una misma zona. En este trabajo seguimos esa idea, pero con 197 parcelas de temporal de Hidalgo, Tlaxcala y Puebla en un mismo ciclo, combinando el análisis de series de tiempo para entender el comportamiento de las variables con un modelo de regresión lineal múltiple para predecir el rendimiento.

Discusión

El análisis de series de tiempo mostró que todas las variables siguen el ciclo de la temporada: en casi todas las parcelas, el valor de cada mes se relacionó con el del mismo mes del año anterior. Esto tiene sentido, ya que las parcelas son de temporal: las lluvias llegan cada año en los mismos meses y el cultivo se siembra y se desarrolla siguiendo esa temporada. Por ello, en lugar de usar el valor del mes anterior para explicar el rendimiento, se decidió medir cada variable en la etapa del cultivo donde es más importante. Aun así, no todos los años fueron iguales: 2022 y 2023 fueron mucho más secos que 2024 y 2025, y en 2023 el cultivo alcanzó un verdor menor y tuvo menos agua, lo que se observó tanto en el EVI como en el MSI.

Los índices satelitales mostraron un comportamiento coherente con el desarrollo del cultivo: el EVI sube cuando la planta crece y baja cuando madura, y el MSI se comporta al revés, ya que la planta tiene más agua cuando está más verde. En cambio, el NDSVI, que se eligió para medir el paso de verde a seco en la madurez, llegó a su valor más alto en agosto, junto con el EVI, y no en septiembre y octubre. Esto indica que, en estas parcelas, el NDSVI responde también al verdor y no solo a la vegetación seca, por lo que no logró separar bien la etapa de madurez.

En el modelo final no quedó ningún índice satelital; las variables que mejor explicaron el rendimiento fueron las de clima y topografía. En las gráficas de dispersión se observó que la lluvia y la temperatura separan a las parcelas en dos grupos: uno con menos lluvia y rendimientos altos, que corresponde principalmente a Chignahuapan y Almoloya, y otro con más lluvia y rendimientos bajos, que corresponde principalmente a Calpulalpan y Singuilucan. Es decir, el clima distingue bien entre zonas, pero no entre parcelas cercanas, ya que los datos de lluvia y temperatura tienen píxeles de varios kilómetros y muchas parcelas vecinas reciben el mismo valor. Por esta razón, dentro de cada grupo el modelo distingue poco entre parcelas. Además, los índices tuvieron una relación débil con el rendimiento, e incluso el EVI tuvo una correlación negativa, lo que indica que en este ciclo las parcelas más verdes no fueron necesariamente las que más rindieron.

El modelo explicó el 61.7 % de la variabilidad del rendimiento, y en la validación cruzada el 56.5 %, con un error promedio de 0.42 t/ha. Como estos valores son muy parecidos, el modelo no está sobreajustado y predice parcelas nuevas casi igual de bien que las que usó para ajustarse. Las parcelas con los errores más grandes fueron AGC_015, AGC_171 y AGC_034, que tuvieron un rendimiento muy bajo a pesar de estar en zonas con buen clima; esto puede deberse a factores que el modelo no considera, como plagas, granizo, el manejo del cultivo o el tipo de suelo.

Al comparar con los antecedentes, la forma de trabajar es muy parecida a la de Iranzo et al. [7], quienes también usaron series de tiempo para ubicar las etapas del cultivo, construyeron las variables por etapa y ajustaron una regresión lineal múltiple; además, su mejor modelo también incluyó la temperatura máxima de la etapa de desarrollo, igual que el nuestro. Barallat Pérez [6] también encontró que las campañas con más calor y menos agua tuvieron menor rendimiento. Sin embargo, ellos obtuvieron valores de R^2 más altos, de hasta 0.98 y 0.93, respectivamente. La diferencia es que esos trabajos comparan el rendimiento entre distintos años en una misma zona, mientras que en este trabajo se compara el rendimiento entre parcelas de un mismo año, donde las diferencias son más pequeñas y dependen de factores más locales. Algo parecido reportaron Gómez Mercado et al. [1] en Almoloya y Apan, cuyo método funcionó a nivel regional, pero no logró captar las diferencias entre localidades.

Finalmente, este trabajo tiene algunas limitaciones. Solo se contó con el rendimiento de un ciclo (2025) y de 138 parcelas, y el rendimiento venía redondeado, por lo que muchas parcelas tienen el mismo valor. Además, los datos de clima tienen una resolución gruesa y no se contó con información del suelo, que en cultivos de temporal influye mucho en el vigor del cultivo [9]. Contar con más años de rendimiento y con datos de suelo podría mejorar el modelo en el futuro.

Uso de la ciencia de datos en la inclusión financiera del sector agro

Muchos productores de cebada de temporal, sobre todo los pequeños, tienen dificultades para acceder a un crédito o a un seguro agrícola, ya que las instituciones financieras no cuentan con suficiente información para saber cuánto podría producir su parcela y, por lo tanto, cuál es el riesgo de prestarles. Al no tener información, el riesgo se percibe como alto, y el productor termina sin financiamiento o con condiciones poco favorables.

La ciencia de datos puede ayudar a reducir este problema. Con información pública y gratuita, como imágenes satelitales y datos de clima y de topografía, es posible estimar el rendimiento de una parcela sin necesidad de visitarla, a un costo muy bajo y para muchas parcelas a la vez. El modelo desarrollado en este trabajo estima el rendimiento de cualquier parcela de la zona a partir de la lluvia en la siembra, la temperatura y la topografía, con un error promedio de 0.42 t/ha.

Esta información podría usarse de varias formas en el sector financiero. Por ejemplo, FIRA o los intermediarios financieros podrían usar el rendimiento estimado para evaluar la capacidad de pago de un productor antes de otorgarle un crédito, o para ajustar los montos y plazos según lo que se espera que produzca su parcela. También podría apoyar a los seguros agrícolas, identificando las zonas con mayor riesgo de bajo rendimiento, como las parcelas donde se espera menos de 3 t/ha.

Además, la aplicación web permite consultar el rendimiento estimado de cada parcela y simular qué pasaría con distintas condiciones de clima, sin necesidad de saber programar. Esto la hace útil tanto para analistas de crédito como para técnicos y productores. Así, la ciencia de datos puede ayudar a que más productores de temporal accedan a financiamiento formal, con decisiones basadas en información y no solo en la experiencia.

Conclusiones

En este trabajo se construyó un modelo para predecir el rendimiento de cebada de 197 parcelas de temporal de Hidalgo, Tlaxcala y Puebla en el ciclo 2025, a partir de índices satelitales, clima y topografía. Para ello se extrajeron los datos de las imágenes .tif, se filtraron las imágenes con nubes, se regularizaron las series y se analizaron las series de tiempo de seis variables.

El análisis de series de tiempo mostró que la lluvia, la temperatura y los índices satelitales siguen el ciclo de la temporada: el valor de cada mes se relaciona con el del mismo mes del año anterior. Por ello, las variables del modelo se construyeron por etapa fenológica del cultivo, usando la escala de Zadoks y la curva del EVI de Planet para ubicar cada etapa en el tiempo.

El modelo final de regresión lineal múltiple quedó con cinco variables: la lluvia en la siembra, la temperatura mínima del ciclo, la temperatura máxima en el llenado del grano, la elevación y la pendiente. Explicó el 61.7 % de la variabilidad del rendimiento y, en la validación cruzada, el 56.5 %, con un error promedio de 0.42 t/ha, por lo que no presenta sobreajuste. Con este modelo se predijo el rendimiento de las 59 parcelas sin rendimiento, que fue de entre 2.63 y 5.02 t/ha.

Respecto a las preguntas planteadas por el reto:

- **¿Qué índice es más importante en la predicción?** Ningún índice satelital quedó en el modelo final. El que más aportó fue el NDSVI en la madurez, que tuvo la correlación más alta con el rendimiento entre los índices y fue el último en ser eliminado por la selección de variables; sin embargo, no mejoró lo suficiente el modelo para conservarse.

- **¿Qué variable climática tiene mayor peso?** La lluvia en la siembra (abril a junio), que tuvo la correlación más fuerte con el rendimiento y fue la variable más significativa del modelo, seguida de la temperatura mínima del ciclo y de la temperatura máxima en el llenado del grano.
- **¿Qué combinación de variables funciona mejor?** La combinación de lluvia en la siembra, temperatura mínima, temperatura máxima en el llenado, elevación y pendiente, que fue la de menor AIC.

El clima resultó más útil que los índices satelitales porque separa bien las zonas de alto y bajo rendimiento; sin embargo, no logra distinguir bien entre parcelas cercanas, ya que los datos de clima tienen una resolución gruesa. Contar con más años de rendimiento y con información del suelo podría mejorar el modelo.

Por último, se desarrolló una aplicación web que ejecuta el modelo y permite consultar el rendimiento de cada parcela, descargar las predicciones y simular el rendimiento con distintas condiciones de clima. Esta herramienta puede apoyar a FIRA y a los intermediarios financieros en la evaluación de créditos y seguros para productores de temporal.

Bibliografía

[1] Gómez Mercado, R., Ortiz Solorio, C. A., Zamora Díaz, M., Soria Ruíz, J., Trinidad Santos, A. y Carballo Carballo, A. (2009). Estimación del rendimiento de cebada (*Hordeum vulgare* L.) maltera con el método FAO. *Agricultura Técnica en México*, 35(1), 13–23.

[2] SIAP (2023). *Panorama de la frontera agrícola: Tlaxcala*. Servicio de Información Agroalimentaria y Pesquera. https://www.gob.mx/cms/uploads/attachment/file/853241/Panorama_FA_2023_TLAX.pdf

[3] Zamora Díaz, M., Solano Hernández, S., Garza García, R., Islas Gutiérrez, J., Huerta Zurita, R. y López Cano, M. (2010). Armida, nueva variedad de cebada maltera para riego en El Bajío. *Revista Mexicana de Ciencias Agrícolas*, 1(5), 723–726.

[4] Quirós Arce, S. D. (2025). *Análisis de la tendencia de erosión y acreción en la línea de costa del Caribe de Costa Rica, utilizando la plataforma Google Earth Engine (GEE) y las imágenes satelitales Sentinel-2* [Trabajo final de graduación de licenciatura, Universidad Nacional]. Heredia, Costa Rica.

[5] Sanmartín Vivar, K. J. (2025). *Análisis multicriterio para la localización óptima de un centro logístico regional utilizando Sistemas de Información Geográfica (SIG) en la provincia de Guayas* [Trabajo de titulación de maestría, Universidad Católica de Santiago de Guayaquil]. Guayaquil, Ecuador.

[6] Barallat Pérez, P. (2020). *Estudio técnico: teledetección aplicada en 6,43 ha de cereales de secano en Collado de Contreras (Ávila) y Yanguas de Eresma (Segovia)* [Trabajo fin de grado, Universidad Politécnica de Madrid]. Madrid, España.

[7] Iranzo, C., Montorio, R. y García-Martín, A. (2022). Estimación de la producción de cebada a partir de imágenes Sentinel-1, Sentinel-2 y variables climáticas. *Revista de Teledetección*, (59), 61–72. https://doi.org/10.4995/raet.2022.15099

[8] Ruiz-Huanca, P., Palacios-Vélez, E., Mejía-Saenz, E., Exebio-García, A., Oropeza-Mota, J. L. y Bolaños-González, M. (2005). Estimación temprana del rendimiento de la cebada mediante uso de sensores remotos. *Terra Latinoamericana*, 23(2), 167–174.

[9] Minuesa Alpín, C. (2021). *Análisis de la oportunidad de aplicación de técnicas de Agricultura de Precisión en cultivos extensivos de secano de la Hoya de Huesca* [Trabajo final de grado, Universitat de Lleida]. Lleida, España.

[10] EOS Data Analytics. (s.f.). *Índices de vegetación*. Recuperado de https://eos.com/es/blog/indices-de-vegetacion/

[11] Agrobit. (s.f.). *Índices de vegetación NDVI, NDRE, GNDVI: Guía técnica completa*. Recuperado de https://agrobit.ag/es/blog/indices-de-vegetacion-ndvi-ndre-gndvi-guia-tecnica-completa/

[12] Alabama Cooperative Extension System (ACES). (s.f.). *Understanding Vegetation Indices Used in Precision Agriculture*. Recuperado de https://www.aces.edu/blog/topics/crop-production/understanding-vegetation-indices-used-in-precision-agriculture/

[13] ClimaProAgro. (s.f.). *Importancia de la temperatura en la agricultura de precisión*. Recuperado de https://www.climaproagro.com/blog/importancia-de-la-temperatura-en-la-agricultura-de-precisin

[14] Instituto Nacional de Investigaciones Forestales, Agrícolas y Pecuarias (INIFAP). (s.f.). *Cebada maltera de temporal en Valles Altos de México*. Gobierno de México. https://www.gob.mx/inifap/articulos/cebada-maltera-de-temporal-en-valles-altos-de-mexico

[15] Scribd. (s.f.). *Estadios de crecimiento del cultivo de trigo*. Recuperado de https://es.scribd.com/document/305792685/Estadios-de-crecimiento-del-cultivo-de-trigo

[16] SmartBarley. (s.f.). *Zacatecas Field*. Recuperado de https://www.smartbarley.com/en/blog/zacatecasfield11112211111111.html

[17] EOS Data Analytics. (s.f.). *Cultivo de cebada*. Recuperado de https://eos.com/es/blog/cultivo-de-cebada/

Anexos

Anexo 1. Aportaciones de los integrantes

A continuación se detalla la participación y las actividades realizadas por cada uno de los integrantes del equipo (estudiantes de Matemáticas Aplicadas) durante el desarrollo del proyecto:

- **Alan Yael Diaz Vizzuett:** Apoyó en el análisis de las bases de datos, dio ideas para la construcción del código y ayudó a revisar los resultados del modelo.
- **Brayan Uriel Islas Sánchez:** Colaboró analizando los datos del proyecto, aportó ideas para hacer el código en R y participó en la revisión de los resultados obtenidos.
- **Brenda Esmeralda Martínez de la Cruz:** Ayudó a revisar y analizar la información de las bases de datos, dio sugerencias para estructurar el código y apoyó interpretando los resultados.
- **Chac de Jesús Moreno Torres:** Participó en el análisis general de los datos, aportó ideas para el desarrollo del código y ayudó a interpretar los resultados finales del proyecto.
- **Jared Sánchez Martínez:** Uso de RStudio para realizar el código de R, también el programar la app en R con `shiny` y `shinylive`, así como la configuración y gestión del repositorio de GitHub.

2. Prompts para la resolución de errores en la aplicación web

Durante la exportación y publicación de la aplicación interactiva, se copiaron y pegaron exactamente los siguientes mensajes de error en la IA para obtener ayuda en su solución:

```
> library(shinylive)
Error en library(shinylive): no hay paquete llamado 'shinylive'
me salio este error

> httpuv::runStaticServer("~/agrocebada/docs")
Error en normalizePath(path.expand(path), winslash, mustWork):
path[1]="C:/Users/rebec/Documents/agrocebada/docs": El sistema no
puede encontrar el archivo especificado
me salio este error

> shinylive::export("~/agrocebada/app", "~/agrocebada/docs")
i Exporting Shiny app from: ~/agrocebada/app
-> Destination: ~/agrocebada/docs
Error in shinylive::export():
! appdir must be a directory, but was provided ~/agrocebada/app.
Run rlang::last_trace() to see where the error occurred.
ottro error
```